

Prompt:

8/17/2026, 9:44:47 PM

lanjut Tahap D

Response:

8/17/2026, 9:44:52 PM

Constructing example

I'm setting up a small four-asset, two-sided portfolio example with binary long/short variables. I'll derive covariance, returns, turnover costs, constraints, and the resulting numeric QUBO matrix.

Constructed an example

Computing a Four-Asset QUBO Portfolio Example

Computed and corrected a four-asset QUBO portfolio optimization example

Worked for 41s

Baik. **Tahap D akan kita jadikan tahap konstruksi matematis konkret.** Di sini kita berhenti berbicara pada level arsitektur dan benar-benar mengambil sebuah kasus kecil, lalu menurunkannya:

data → trade candidates → objective → QUBO → Ising → QAOA

Saya akan menggunakan **4 aset** agar seluruh matriks masih bisa kita lihat secara eksplisit.

Catatan penting: angka di bawah adalah angka sintetis untuk demonstrasi matematis, bukan estimasi pasar aktual. Nanti ketika masuk implementasi, seluruh angka ini akan berasal dari data historis.

D.1. Kasus konkret

Misalkan pada waktu t , sistem sedang mengevaluasi empat kandidat:

$$A = \{BTC, ETH, AAPL, GLD\}.$$

Kita ingin memilih **tepat 2 trade**.

Setiap aset memiliki tiga kemungkinan:

$$LONG, \quad SHORT, \quad FLAT.$$

Dan setiap trade yang dipilih memiliki risk budget:

$$R_{\max} = \$1.$$

D.2. Tahap pertama: menentukan stop loss dan position size

Misalkan sinyal menghasilkan:

Asset	Entry	SL distance
BTC	\$60,000	1.00%
ETH	\$3,000	1.20%
AAPL	\$200	1.00%
GLD	\$250	0.80%

Untuk setiap trade:

$$q_i = \frac{R_{\max}}{|P_i - SL_i|}.$$

BTC

Stop distance:

$$60000(0.01) = 600.$$

Sehingga:

$$q_{BTC} = \frac{1}{600} = 0.001667 \text{ BTC}.$$

ETH

$$d_{ETH} = 3000(0.012) = 36.$$

Sehingga:

$$q_{ETH} = \frac{1}{36} = 0.02778 \text{ ETH}.$$

AAPL

$$d_{AAPL} = 200(0.01) = 2.$$

Sehingga:

$$q_{AAPL} = 0.5 \text{ saham}.$$

GLD

$$d_{GLD} = 250(0.008) = 2.$$

Sehingga:

$$q_{GLD} = 0.5.$$

Jadi **setiap trade yang dipilih mempunyai nominal posisi berbeda**, tetapi jika SL tersentuh:

$$\boxed{\text{loss} \approx \$1.}$$

Ini penting karena optimizer nantinya tidak boleh membandingkan BTC dan AAPL hanya berdasarkan nominal harga.

D.3. Expected trade value

Dari Tahap B, model forecasting kita menghasilkan expected net PnL untuk satu trade yang sudah dinormalisasi terhadap risk \$1.

Misalkan:

$$\tilde{\mu} = \begin{bmatrix} 0.18 \\ 0.15 \\ 0.10 \\ 0.08 \end{bmatrix}.$$

Artinya:

Asset	Expected net PnL
BTC	\$0.18
ETH	\$0.15
AAPL	\$0.10
GLD	\$0.08

Ini bukan berarti model berkata:

BTC pasti menghasilkan \$0.18.

Melainkan:

$$E[\text{PnL}_i | S_t] = \$0.18.$$

D.4. Covariance antar-trade

Sekarang bagian yang sangat penting.

Misalkan covariance matrix dari **risk-normalized PnL** adalah:

$$\Sigma = \begin{pmatrix} 0.6400 & 0.5400 & 0.0900 & -0.0240 \\ 0.5400 & 0.8100 & 0.0810 & -0.0135 \\ 0.0900 & 0.0810 & 0.2025 & -0.02025 \\ -0.0240 & -0.0135 & -0.02025 & 0.0900 \end{pmatrix}.$$

Urutan:

$$(BTC, ETH, AAPL, GLD).$$

Perhatikan:

$$\Sigma_{BTC,ETH} = 0.54.$$

Sangat positif.

Sedangkan:

$$\Sigma_{AAPL,GLD} = -0.02025.$$

Negatif.

Ini akan menghasilkan konsekuensi yang menarik.

D.5. Mengapa covariance menjadi penting?

Bandungkan dua portfolio:

Portfolio A

LONG BTC

dan:

LONG ETH.

Expected value:

$$0.18 + 0.15 = 0.33.$$

Tetapi variance:

$$\sigma^2 = \Sigma_{BTC,BTC} + \Sigma_{ETH,ETH} + 2\Sigma_{BTC,ETH}.$$

Sehingga:

$$= 0.64 + 0.81 + 2(0.54)$$

$$= 2.53.$$

Portfolio B

LONG AAPL

dan:

LONG GLD.

Expected value:

$$0.10 + 0.08 = 0.18.$$

Variance:

$$= 0.2025 + 0.09 + 2(-0.02025)$$

$$= 0.252.$$

Jadi:

$$BTC + ETH : \quad EV = 0.33, \quad Var = 2.53$$

sedangkan:

$$AAPL + GLD : \quad EV = 0.18, \quad Var = 0.252.$$

Ini tepat alasan kita tidak boleh melakukan:

sort predicted return

lalu mengambil dua teratas.

D.6. Risk aversion

Misalkan:

$$\lambda = 0.1.$$

Objective dasar:

$$U(x) = \boldsymbol{\mu}^T x - \lambda x^T \Sigma x.$$

Untuk BTC+ETH:

$$U = 0.33 - 0.1(2.53)$$

$$= 0.077.$$

Untuk AAPL+GLD:

$$U = 0.18 - 0.1(0.252)$$

$$= 0.1548.$$

Maka:

$$\boxed{AAPL + GLD > BTC + ETH.}$$

Walaupun:

$$EV_{BTC+ETH} > EV_{AAPL+GLD}.$$

Ini adalah perilaku yang kita inginkan dari optimizer.

D.7. Sekarang masukkan factor exposure

Sekarang kita ingin sistem tidak hanya melihat covariance.

Misalkan ada faktor:

$$F_{DXY}.$$

Beta ilustratif:

$$\beta_{DXY} = \begin{bmatrix} -0.8 \\ -0.6 \\ -0.3 \\ +0.2 \end{bmatrix}.$$

Artinya secara ilustratif:

- BTC sensitif negatif terhadap DXY,
- ETH negatif,
- AAPL negatif,
- GLD sedikit positif.

Exposure portfolio:

$$E_{DXY} = \beta_{DXY}^T x.$$

Kita ingin menghindari exposure DXY terlalu besar.

Untuk demonstrasi pertama kita targetkan:

$$E_{DXY}^{target} = 0.$$

Penalty:

$$P_F (E_{DXY})^2.$$

Misalkan:

$$P_F = 0.5.$$

D.8. Contoh factor exposure

Untuk:

$$LONG\ BTC + LONG\ ETH,$$

kita mendapatkan:

$$E_{DXY} = -0.8 - 0.6 = -1.4.$$

Penalty:

$$0.5(-1.4)^2 = 0.98.$$

Cukup besar.

Sedangkan AAPL+GLD:

$$E_{DXY} = -0.3 + 0.2 = -0.1.$$

Penalty:

$$0.5(-0.1)^2 = 0.005.$$

Jadi optimizer semakin menyukai AAPL+GLD.

D.9. Transaction cost

Misalkan biaya efektif:

$$c = \begin{bmatrix} 0.02 \\ 0.02 \\ 0.01 \\ 0.01 \end{bmatrix}.$$

Jadi:

- BTC: \$0.02,
- ETH: \$0.02,
- AAPL: \$0.01,
- GLD: \$0.01.

Biaya ini bisa berasal dari:

spread + commission + estimated slippage.

D.10. Sekarang kita buat decision variables

Untuk setiap aset kita membutuhkan dua binary variable:

$$y_i^L$$

dan:

$$y_i^S.$$

Maka:

$$y_{BTC}^L, \quad y_{BTC}^S$$

$$y_{ETH}^L, \quad y_{ETH}^S$$

$$y_{AAPL}^L, \quad y_{AAPL}^S$$

$$y_{GLD}^L, \quad y_{GLD}^S.$$

Total:

8 binary variables.

D.11. Kita susun vector

$$\mathbf{y} = \begin{bmatrix} y_{BTC}^L \\ y_{ETH}^L \\ y_{AAPL}^L \\ y_{GLD}^L \\ y_{BTC}^S \\ y_{ETH}^S \\ y_{AAPL}^S \\ y_{GLD}^S \end{bmatrix}.$$

Kemudian signed position:

$$x_i = y_i^L - y_i^S.$$

Sehingga:

$$\mathbf{x} = \begin{bmatrix} x_{BTC} \\ x_{ETH} \\ x_{AAPL} \\ x_{GLD} \end{bmatrix}.$$

D.12. Constraint pertama: tidak boleh long dan short bersamaan

Kita ingin:

$$y_i^L + y_i^S \leq 1.$$

Daripada constraint inequality, untuk QUBO kita gunakan penalty:

$$P_{LS} \sum_i y_i^L y_i^S.$$

Misalkan:

$$P_{LS} = 5.$$

Jika:

$$y_i^L = y_i^S = 1,$$

maka kita mendapatkan penalty:

5.

Karena benefit trade normal jauh lebih kecil, solusi optimal akan menghindarinya.

D.13. Constraint kedua: tepat dua posisi

Untuk contoh ini kita pakai:

$$K = 2.$$

Kita inginkan:

$$\sum_i (y_i^L + y_i^S) = 2.$$

Gunakan:

$$P_K [\sum_i (y_i^L + y_i^S) - 2]^2.$$

Misalkan:

$$P_K = 3.$$

Perhatikan bahwa ini **memaksa tepat 2 trade**, bukan "maksimal 2 trade".

Untuk implementasi produksi nanti, kita bisa mengubahnya menjadi inequality dengan slack variable.

D.14. Objective lengkap

Sekarang:

$$E(\mathbf{y}) = -\tilde{\boldsymbol{\mu}}^T \mathbf{x} + \lambda \mathbf{x}^T \Sigma \mathbf{x} + C(\mathbf{y}) + P_F (\beta^T \mathbf{x})^2 + P_{LS} \sum_i y_i^L y_i^S + P_K (\sum_i (y_i^L + y_i^S) - 2)^2.$$

Inilah **objective utama Tahap D**.

D.15. Mengapa expected return diberi tanda minus?

Karena QUBO biasanya kita tulis sebagai:

$$\min E.$$

Sedangkan kita sebenarnya ingin:

$$\max U.$$

Karena:

$$\max U \Leftrightarrow \min(-U).$$

Jadi:

$$-\tilde{\boldsymbol{\mu}}^T \mathbf{x}$$

adalah reward yang diubah menjadi cost.

D.16. Kita sekarang ekspansi bagian return

Karena:

$$x_i = y_i^L - y_i^S,$$

maka:

$$-\tilde{\boldsymbol{\mu}}^T \mathbf{x} = -\sum_i \tilde{\mu}_i y_i^L + \sum_i \tilde{\mu}_i y_i^S.$$

Tambahkan transaction cost:

$$c_i(y_i^L + y_i^S).$$



Maka linear coefficient awal:

Long

$$c_i^L = -\tilde{\mu}_i + c_i$$

Short

$$c_i^S = +\tilde{\mu}_i + c_i.$$

Sehingga:

Asset	Long coefficient	Short coefficient
BTC	-0.16	\$0.20\$
ETH	-0.13	\$0.17\$
AAPL	-0.09	\$0.11\$
GLD	-0.07	\$0.09\$

Sebelum penalty.

Ini sudah sangat intuitif.

Untuk BTC:

$$-0.16$$

membuat LONG menarik.

Sedangkan:

$$+0.20$$

membuat SHORT tidak menarik.

D.17. Risk term

Kita memiliki:

$$x^T \Sigma x.$$

Dengan:

$$x = y^L - y^S.$$

Maka:

$$x^T \Sigma x = (y^L - y^S)^T \Sigma (y^L - y^S).$$

Expand:

$$= (y^L)^T \Sigma y^L - 2(y^L)^T \Sigma y^S + (y^S)^T \Sigma y^S.$$

Ini adalah bagian yang menghasilkan **coupling antar-qubit**.

D.18. Contoh coupling BTC–ETH

Dari:

$$\Sigma_{BTC,ETH} = 0.54.$$

Untuk dua LONG:

$$\lambda(2)(0.54)y_{BTC}^L y_{ETH}^L.$$

Dengan:

$$\lambda = 0.1,$$

maka:

$$0.108 y_{BTC}^L y_{ETH}^L.$$

Artinya memilih BTC dan ETH secara bersamaan menghasilkan additional risk cost.

Inilah analogi langsung:

$\text{financial correlation} \leftrightarrow \text{qubit coupling}.$

D.19. Contoh AAPL–GLD

$$\Sigma_{AAPL, GLD} = -0.02025.$$

Maka coupling:

$$\begin{aligned} 2\lambda\Sigma_{AAPL, GLD} &= 2(0.1)(-0.02025) \\ &= -0.00405. \end{aligned}$$

Jadi:

$$-0.00405y_{AAPL}^L y_{GLD}^L.$$

Negative coupling berarti memilih keduanya bersama-sama justru mengurangi risk term.

Ini adalah salah satu alasan kombinasi AAPL+GLD menjadi menarik.

D.20. Factor penalty juga menghasilkan coupling

Kita mempunyai:

$$P_F(\beta^T x)^2.$$

Expand:

$$P_F \sum_i \sum_j \beta_i \beta_j x_i x_j.$$

Jadi jika dua aset mempunyai beta factor yang sama arahnya, mereka memperoleh positive coupling.

Dengan kata lain:

factor exposure $\rightarrow$ additional graph coupling.
--

D.21. Sekarang kita dapat membentuk QUBO

Secara umum:

$$E(\mathbf{y}) = \mathbf{y}^T Q \mathbf{y} + \mathbf{c}^T \mathbf{y} + C.$$

Untuk contoh kita, dengan urutan 8 variable tadi, matrix Q yang dihasilkan adalah:

$$Q \approx \begin{pmatrix} 3.384 & 3.294 & 3.129 & 2.918 & 5.116 & 2.706 & 2.871 & 3.082 \\ 3.294 & 3.261 & 3.098 & 2.939 & 2.706 & 5.239 & 2.902 & 3.061 \\ 3.129 & 3.098 & 3.065 & 2.968 & 2.871 & 2.902 & 5.435 & 3.032 \\ 2.918 & 2.939 & 2.968 & 3.029 & 3.082 & 3.061 & 3.032 & 5.471 \\ 5.116 & 2.706 & 2.871 & 3.082 & 3.384 & 3.294 & 3.129 & 2.918 \\ 2.706 & 5.239 & 2.902 & 3.061 & 3.294 & 3.261 & 3.098 & 2.939 \\ 2.871 & 2.902 & 5.435 & 3.032 & 3.129 & 3.098 & 3.065 & 2.968 \\ 3.082 & 3.061 & 3.032 & 5.471 & 2.918 & 2.939 & 2.968 & 3.029 \end{pmatrix}.$$

dan:

$$\mathbf{c} = \begin{bmatrix} -12.16 \\ -12.13 \\ -12.09 \\ -12.07 \\ -11.80 \\ -11.83 \\ -11.89 \\ -11.91 \end{bmatrix}.$$

Konstanta:

$$C = 12.$$

D.22. Kenapa coefficient-nya terlihat besar?

Ini pertanyaan yang mungkin langsung muncul.

Karena:

$$P_K = 3$$

dan:

$$P_{LS} = 5$$

menghasilkan coefficient penalty yang jauh lebih besar daripada expected return.

Itu **memang disengaja**.

Penalty harus cukup besar sehingga optimizer lebih memilih:

solusi feasible dengan utility sedikit lebih rendah

daripada:

solusi infeasible dengan utility tinggi.

Namun dalam sistem produksi, penalty tidak boleh dipilih asal besar. Kita akan membuat metode sistematis untuk menentukan lower bound penalty berdasarkan upper bound objective benefit.

D.23. Mari kita lihat solusi optimal

Kita dapat melakukan brute-force karena hanya ada:

$$2^8 = 256$$

state.

Untuk contoh ini, ground-state solution adalah:

$$y_{AAPL}^L = 1$$

dan:

$$y_{GLD}^L = 1.$$

Semua lainnya:

$$0.$$

Jadi:

$$\mathbf{y}^* = [0, 0, 1, 1, 0, 0, 0, 0]^T.$$

Dan:

$$\mathbf{x}^* = [0, 0, +1, +1]^T.$$

Artinya:

LONG AAPL

LONG GLD

dan:

BTC = FLAT

ETH = FLAT.

D.24. Mari kita verifikasi objective secara manual

Expected value:

$$EV = 0.10 + 0.08 = 0.18.$$

Risk:

$$x^T \Sigma x = 0.252.$$

Risk penalty:

$$\lambda Risk = 0.1(0.252) = 0.0252.$$

Transaction cost:

$$0.01 + 0.01 = 0.02.$$

DXY exposure:

$$-0.3 + 0.2 = -0.1.$$

Factor penalty:

$$0.5(-0.1)^2 = 0.005.$$

Exclusivity penalty:

$$0.$$



Count penalty:

$$0.$$

Maka:

$$E^* = -0.18 + 0.0252 + 0.02 + 0.005.$$

Sehingga:

$$E^* = -0.1298.$$

Karena kita melakukan minimization, semakin negatif semakin baik.

D.25. Bandingkan dengan BTC + ETH

Untuk:

$$x = [1, 1, 0, 0].$$

Expected:

$$0.33.$$

Risk:

$$2.53.$$

DXY exposure:

$$-1.4.$$

Maka:

$$E = -0.33 + 0.1(2.53) + 0.04 + 0.5(1.4)^2.$$

$$= -0.33 + 0.253 + 0.04 + 0.98.$$

$$E = 0.943.$$

Jauh lebih buruk.

D.26. Ini memberikan insight yang sangat penting

Kalau kita hanya memakai expected return:

$$BTC + ETH$$

akan menang.

Tetapi ketika kita mempertimbangkan:

$$\text{return} + \text{risk} + \text{factorexposure} + \text{transactioncost},$$

hasilnya:

$$AAPL + GLD.$$

Inilah alasan optimizer combinatorial kita diperlukan.

D.27. Sekarang kita ubah QUBO menjadi Ising

Kita gunakan:

$$y_i = \frac{1 - Z_i}{2}.$$

Dengan:

$$Z_i \in \{-1, +1\}.$$

Interpretasi:

$$Z_i = -1 \Rightarrow y_i = 1$$

dan:

$$Z_i = +1 \Rightarrow y_i = 0.$$

D.28. Transformasi pasangan

Untuk:

$$y_i y_j$$

kita memperoleh:

$$y_i y_j = \frac{1}{4}(1 - Z_i - Z_j + Z_i Z_j).$$

Inilah formula yang mengubah QUBO menjadi Ising.

D.29. Bentuk Ising

Secara umum:

$$H = C' + \sum_i a_i Z_i + \sum_{i < j} b_{ij} Z_i Z_j.$$

Konstanta:

$$C'$$

boleh dibuang karena tidak mempengaruhi state minimum.

Sehingga:

$$H = \sum_i a_i Z_i + \sum_{i < j} b_{ij} Z_i Z_j.$$

D.30. Hubungan QUBO → Ising

Jika:

$$E(y) = y^T Q y + c^T y + C,$$

maka dengan konvensi $y_i^2 = y_i$, define:

$$b_i = c_i + Q_{ii}.$$

Kemudian:

$$a_i = -\frac{1}{2}b_i - \frac{1}{2} \sum_{j \in \mathbb{I}} Q_{ij}$$

dan:

$$b_{ij} = \frac{1}{2}Q_{ij}.$$

D.31. Hasil Ising untuk contoh kita

Coefficient linear a_i :

$$a_1 = -7.170$$

$$a_2 = -7.185$$

$$a_3 = -7.205$$

$$a_4 = -7.215$$

$$a_5 = -7.350$$

$$a_6 = -7.335$$

$$a_7 = -7.305$$

$$a_8 = -7.295.$$

Dan pairwise coupling:

$$b_{ij} = \frac{Q_{ij}}{2}.$$

Misalnya:

$$b_{12} = 1.647$$

karena:

$$Q_{12} = 3.294.$$

Sedangkan:

$$b_{13} = 1.5645.$$

D.32. Hati-hati dengan konvensi Hamiltonian

Dalam banyak literatur Ising/QAOA kita menggunakan:

$$H = \sum_i h_i Z_i + \sum_{i < j} J_{ij} Z_i Z_j.$$

Tetapi dalam formulasi yang pernah kita gunakan untuk skripsimu:

$$H = - \sum_i h_i Z_i - \sum_{i < j} J_{ij} Z_i Z_j.$$

Jadi:

$$h_i = -a_i$$

dan:

$$J_{ij} = -b_{ij}.$$

Dengan demikian:

$$h_i > 0$$

dan banyak J_{ij} menjadi negatif untuk contoh kita.

Ini **bukan perbedaan fisika**, hanya perbedaan konvensi tanda.

Kita harus menetapkan satu konvensi secara konsisten di implementasi.

D.33. Bentuk Hamiltonian akhir

Menggunakan konvensi skripsimu:

$$H_C = - \sum_i h_i Z_i - \sum_{i < j} J_{ij} Z_i Z_j.$$

Inilah:

Cost Hamiltonian.

Dan sekarang kita sudah benar-benar mempunyai Hamiltonian yang berasal dari masalah trading.

Bukan Hamiltonian yang dibuat sembarang.

D.34. Interpretasi fisiknya

Ini bagian yang menurutku sangat menarik untuk penelitianmu.

Dalam sistem ini:

$$h_i$$

merepresentasikan **local preference** terhadap keputusan tertentu.

Sedangkan:

$$J_{ij}$$

merepresentasikan **interaction** antara dua keputusan.

Interaction tersebut dapat berasal dari:

covariance

+

factor exposure

+

constraints.

Jadi:

financial dependency → Ising coupling.

D.35. Ini persis alasan Ising sangat cocok

Bayangkan graph:

$$BTC \leftrightarrow ETH$$

memiliki coupling kuat karena:

$$\rho_{BTC,ETH} \gg 0.$$

Sedangkan:

$$AAPL \leftrightarrow GLD$$

memiliki coupling negatif karena covariance negatif.

Maka sistem kita secara matematis berubah menjadi:

$\text{financial interaction graph} \rightarrow \text{spin interaction graph.}$

D.36. Sekarang kita sampai ke QAOA

Setelah mendapatkan:

$$H_C,$$

kita membutuhkan state yang mencari:

$\arg \min H_C.$

QAOA menggunakan dua Hamiltonian.

Cost Hamiltonian

H_C

yang baru saja kita turunkan.

Mixer Hamiltonian

Untuk standard QAOA:

$$H_M = \sum_i X_i.$$

Atau sering ditulis:

$$H_M = - \sum_i X_i.$$

Tanda tidak terlalu penting selama konvensinya konsisten dengan unitary.

D.37. State awal

Standard QAOA:

$$|s\rangle = |+\rangle^{\otimes n}$$

dengan:

$$|+\rangle = \frac{|0\rangle + |1\rangle}{\sqrt{2}}.$$

Untuk:

$$n = 8,$$

kita memiliki:

$$|s\rangle = |+\rangle^{\otimes 8}.$$

D.38. Operator QAOA

Cost unitary:

$$U_C(\gamma) = e^{-i\gamma H_C}.$$

Mixer:

$$U_M(\beta) = e^{-i\beta H_M}.$$

Untuk $p = 1$:

$$|\psi(\gamma, \beta)\rangle = U_M(\beta)U_C(\gamma)|+\rangle^{\otimes 8}.$$

Untuk p layer:

$$|\psi_p\rangle = \prod_{k=1}^p U_M(\beta_k)U_C(\gamma_k)|+\rangle^{\otimes 8}.$$

D.39. Classical optimizer kemudian mencari

$$(\gamma^*, \beta^*) = \arg \min \langle \psi_p | H_C | \psi_p \rangle.$$

Ini menghasilkan parameter:

$$\gamma_1, \dots, \gamma_p$$

dan:

$$\beta_1, \dots, \beta_p.$$

Kemudian kita sampling quantum circuit.

D.40. Apa yang keluar dari QAOA?

Misalnya hasil sampling:

$$|00110000\rangle$$

dengan probabilitas tinggi.

Dengan mapping:

$$y_i = \frac{1 - Z_i}{2},$$

kita decode:

$$y_{AAPL}^L = 1$$

dan:

$$y_{GLD}^L = 1.$$

Sehingga:

LONG AAPL

LONG GLD.

D.41. Tetapi jangan langsung percaya bitstring paling sering

Ini sangat penting untuk trading.

Quantum optimizer dapat menghasilkan:

$$P(y)$$

bukan hanya satu solusi.

Misalnya:

State	Probability
AAPL + GLD	0.41
ETH + GLD	0.17
BTC + GLD	0.12
BTC – ETH	0.08
lainnya	0.22

Maka kita sebenarnya mendapatkan **distribution over candidate portfolios**.

Ini bisa menjadi sangat berguna untuk sistem kita.

D.42. Kita bisa mendefinisikan confidence

Misalnya:

$$P^* = P(y^*).$$

Jika:

$$P^* = 0.41,$$

confidence tidak terlalu tinggi.

Tetapi jika:

$$P^* = 0.85,$$

maka optimizer sangat konsisten terhadap solusi tersebut.

Kita dapat menggunakan:

$$P^* > P_{\min}$$

sebagai salah satu syarat eksekusi.

D.43. Bahkan entropy yang pernah kamu pelajari bisa masuk lagi

Kamu sebelumnya telah mempelajari Von Neumann entropy.

Di sini kita dapat menghitung entropy distribusi solusi:

$$H_{\text{Shannon}} = - \sum_x P(x) \log P(x).$$

Jika distribusi sangat terkonsentrasi:

$$P(x^*) \approx 1,$$

maka entropy rendah.

Jika distribusi tersebar:

$$P(x) \approx \frac{1}{2^N},$$

entropy tinggi.

Jadi kita bisa mendefinisikan:

optimizer confidence $\sim$ low solution entropy.

Ini akan menjadi hubungan yang menarik dengan penelitianmu mengenai entropy.

D.44. Dan sekarang kita bisa menghubungkan dengan EPG

Di penelitianmu sebelumnya, EPG menghasilkan:

$$x_{\text{EPG}}.$$

Misalnya:

$$x_{\text{EPG}} = [0, 0, +1, +1].$$

Ini dapat digunakan sebagai:

warm-start.

Daripada:

$$|+\rangle^{\otimes 8},$$

kita dapat membangun initial state yang lebih dekat ke solusi EPG.

Secara konseptual:

EPG $\rightarrow$ candidate equilibrium $\rightarrow$ QAOA initial state.

D.45. Dan sekarang kita mendapatkan arsitektur yang sangat kuat

Tahap A:

MarketState



↓

Tahap B:

ConditionalForecast

↓

Tahap C:

TradingUtility

↓

Tahap D:

QUBO → Ising → QAOA

↓

kemudian:

TradeExecution

D.46. Tetapi ada satu koreksi penting terhadap desain awal kita

Kita **belum boleh** mengatakan:

"QAOA memutuskan TP dan SL."

Dalam formulasi yang baru kita bangun, QAOA memutuskan:

which trades and which direction

sedangkan:

SL, TP, position size

sebaiknya berasal dari **trade construction layer**.

Untuk tahap berikutnya kita bisa membuatnya jauh lebih sophisticated.

Misalnya untuk setiap kandidat:

i

bukan hanya satu state:

$LONG_i.$

Tetapi:

$LONG_{i,1}$

untuk:

$SL = 1ATR, TP = 2ATR,$

$LONG_{i,2}$

untuk:

$SL = 1.5ATR, TP = 3ATR,$

dan seterusnya.

Maka optimizer sebenarnya memilih:

$(asset, direction, entry, SL, TP)$

secara bersamaan.

Tetapi jumlah qubit akan meningkat.

D.47. Ini membawa kita ke formulasi yang jauh lebih menarik

Daripada:

$x_i \in \{-1, 0, +1\},$

kita bisa membuat:

$x_{i,d,e,s,p} \in \{0, 1\}.$

Contohnya:

$$X_{\text{BTC},L,\text{limit},1\text{ATR},2\text{ATR}}$$

Dengan demikian QUBO dapat memilih:

BTC long, limit entry tertentu, SL 1 ATR, TP 2 ATR.

Ini jauh lebih dekat dengan sistem trading yang kamu bayangkan sejak awal.

Namun tentu saja:

$$N_{\text{qubit}}$$

akan meningkat sangat cepat.

D.48. Dan di sinilah kita harus berhati-hati

Misalnya:

$$N_{\text{asset}} = 50$$

dan kita punya:

- 2 directions,
- 3 entry types,
- 3 SL choices,
- 4 TP choices.

Maka:

$$50 \times 2 \times 3 \times 3 \times 4 = 3600$$

binary variables.

Artinya:

3600 qubits

bahkan sebelum menambahkan auxiliary variables.

Ini tidak realistis untuk NISQ hardware saat ini.

Maka kita membutuhkan:

candidate reduction

sebelum quantum optimization.

D.49. Ini membuat pipeline produksi kita menjadi

1000 + *assets*

↓

classical screening

↓

20 – 50*candidates*

↓

trade construction

↓

5 – 10*candidates*

↓

QUBO

↓

10 – 20 qubits

untuk prototype.

Baru kemudian kita menguji:

20 → 50 → 100

qubits pada simulator/quantum hardware yang tersedia.

D.50. Jadi Tahap D menghasilkan sesuatu yang sangat konkret

Kita sekarang mempunyai:

Decision space

$$y_i^L, y_i^S \in \{0, 1\}.$$

Signed position

$$x_i = y_i^L - y_i^S.$$

Utility

$$U = \mu^T x - \lambda x^T \Sigma x - C - P_F (\beta^T x)^2 - P_{\text{constraint}}.$$

QUBO

$$E(y) = y^T Q y + c^T y + C.$$

Ising

$$H_C = \sum_i a_i Z_i + \sum_{i < j} b_{ij} Z_i Z_j.$$

atau dengan konvensi skripsimu:

$$H_C = - \sum_i h_i Z_i - \sum_{i < j} J_{ij} Z_i Z_j.$$

QAOA

$$|\psi_p(\gamma, \beta)\rangle = \prod_{k=1}^p e^{-i\beta_k H_M} e^{-i\gamma_k H_C} |+\rangle^{\otimes n}.$$

Output

$$P(\text{LONG/SHORT/FLAT combinations})$$



D.51. Satu insight besar yang saya ingin kamu pegang

Perhatikan rantai berikut:

$$\Sigma_{ij}$$

↓

$$Q_{ij}$$

↓

$$J_{ij}$$

↓

$$Z_i Z_j.$$

Jadi ada hubungan matematis langsung:

asset covariance $\rightarrow$ QUBO coupling $\rightarrow$ Ising coupling $\rightarrow$ two-qubit interaction.

Dengan kata lain, **struktur korelasi pasar diterjemahkan menjadi struktur interaksi qubit**.

Dan factor model memberikan coupling tambahan:

market factors $\rightarrow$ factor exposure penalty $\rightarrow$ additional J_{ij} .

Jadi nanti jika kita masukkan:

BTC, ETH, SPX, DXY, GOLD, VIX

sebagai market factors, mereka bukan sekadar indikator yang kita tampilkan pada chart. Mereka benar-benar dapat memengaruhi **Hamiltonian trading**.

D.52. Tetapi Tahap D belum selesai secara sistem trading

Yang baru kita bangun adalah:

Decision Engine.

Kita belum membangun:

Execution Engine

dan:

Position Management Engine.

Padahal itu persis bagian yang kamu tanyakan di awal:

kalau order belum terpanggil, apakah masih valid?

kalau floating loss, apakah dipertahankan?

kalau floating profit, apakah SL dinaikkan?

kalau profit tinggi, apakah TP diperpanjang?

Itu tidak seharusnya ditangani oleh QUBO statis.

Kita membutuhkan **dynamic receding-horizon optimization**.

Dan menurutku itu adalah **Tahap E yang paling menarik**.

Kita akan mengubah sistem dari:

optimizer menghasilkan trade

menjadi:

optimizer menghasilkan policy

dengan state:

S_t

yang terus berubah.

Secara matematis:

$$\pi^*(S_t) = \arg \max_a E[U_{t:t+H} \mid S_t, a].$$

Jadi setiap satu jam, atau bahkan setiap beberapa menit:

$$S_t \rightarrow \text{re-optimize} \rightarrow a_t \rightarrow S_{t+\Delta t} \rightarrow \text{re-optimize}.$$

Di situlah sistem kita mulai menjadi benar-benar "quantitative trading system", bukan sekadar portfolio optimizer.

Dan untuk Tahap E nanti kita perlu membangun secara matematis **state machine posisi: PENDING → OPEN → BEP → TRAILING → EXIT**, lalu menggabungkannya dengan **model probabilitas TP/SL, expected remaining value, trailing-stop optimization, order cancellation/replacement, dan receding-horizon/QUBO re-optimization**. Itu akan langsung menjawab empat mekanisme trading yang kamu bayangkan pada awal percakapan.