

Prompt:

8/17/2026, 9:53:11 PM

lanjut Tahap J

Response:

8/17/2026, 9:53:12 PM


Tentu. **Tahap J adalah tahap yang sangat penting**, karena di sini seluruh gagasan A-I kita satukan menjadi **satu spesifikasi matematis formal**. Setelah Tahap J selesai, kita seharusnya dapat mengambil dokumen ini dan menerjemahkannya hampir satu-ke-satu menjadi software.

Saya akan membuatnya cukup formal, tetapi tetap menjaga interpretasi finansialnya.

Tahap J — Formal Mathematical Specification

J.0. Tujuan Tahap J

Kita ingin mendefinisikan sistem:



sebagai sebuah **dynamic stochastic control system**.

Secara abstrak:

M = (S, A, P, R)

dengan:

- S: state space,
- A: action space,
- P: transition dynamics,
- R: reward/PnL function.

Namun kita **tidak perlu langsung memaksakan sistem menjadi reinforcement learning**. Kita dapat menggunakan formulasi ini sebagai kerangka matematis, sementara policy kita dibangun melalui forecasting + optimization.

J.1. Notasi utama

Kita definisikan:

$$t = 1, 2, \dots, T$$

sebagai indeks waktu.

Jumlah aset:

$$N.$$

Harga asset i :

$$P_{i,t}.$$

Vektor harga:

$$\mathbf{P}_t = (P_{1,t}, P_{2,t}, \dots, P_{N,t})^T.$$

J.2. Return

Kita menggunakan log-return:

$$r_{i,t} = \ln\left(\frac{P_{i,t}}{P_{i,t-1}}\right).$$

Vektor return:

$$\mathbf{r}_t = (r_{1,t}, \dots, r_{N,t})^T.$$

Dengan demikian:

$$\mathbf{r}_t \in \mathbb{R}^N.$$

J.3. Information set

Semua keputusan pada waktu t harus berdasarkan:

$$F_t = \sigma(\mathbf{r}_1, \dots, \mathbf{r}_t, \mathbf{f}_1, \dots, \mathbf{f}_t, \mathbf{o}_1, \dots, \mathbf{o}_t)$$

dengan:

- $\mathbf{f}_t$: market factors,
- $\mathbf{o}_t$: order-book/execution information.

Keputusan:

$$a_t = \pi(F_t).$$

Ini menjadi aturan kausal utama seluruh sistem.

J.4. Market factor vector

Kita tidak ingin model hanya melihat harga asset yang ditradingkan.

Kita definisikan:

$$\mathbf{f}_t = \begin{bmatrix} r_t^{BTC} \\ r_t^{ETH} \\ r_t^{Gold} \\ r_t^{DXY} \\ r_t^{SPX} \\ r_t^{VIX} \\ \vdots \end{bmatrix}.$$

Komposisinya dapat berubah berdasarkan asset class.

Misalnya untuk crypto:

$$\mathbf{f}_t^{crypto} = [r_t^{BTC}, r_t^{ETH}, r_t^{DXY}, r_t^{Gold}, r_t^{SPX}]^T.$$

Untuk saham:

$$\mathbf{f}_t^{equity} = [r_t^{SPX}, r_t^{DXY}, r_t^{Gold}, r_t^{VIX}]^T.$$

J.5. Factor model

Kita menggunakan:

$$\mathbf{r}_t = B_t \mathbf{f}_t + \boldsymbol{\epsilon}_t$$

dengan:

$$B_t \in \mathbb{R}^{N \times K}.$$

Elemen:

$$B_{ik,t}$$

adalah exposure asset i terhadap factor k .

J.6. Estimasi beta

Secara sederhana:

$$\beta_{ik,t} = \frac{\text{Cov}(r_i, f_k)}{\text{Var}(f_k)}.$$

Tetapi kita ingin multivariate regression:

$$\mathbf{B}_t = \arg \min_B \sum_{\tau=t-W+1}^t \|\mathbf{r}_\tau - B \mathbf{f}_\tau\|_2^2.$$

W adalah rolling estimation window.

J.7. Residual return

Setelah memperoleh B_t :

$$\hat{\boldsymbol{\epsilon}}_t = \mathbf{r}_t - B_t \mathbf{f}_t.$$

Residual ini mencoba menangkap:

asset-specific movement.

J.8. Expected return

Model forecasting kita menghasilkan:

$$\hat{\mu}_{t+1} = E[\mathbf{r}_{t+1} \mid \mathbf{F}_t].$$

Tetapi kita dapat memecahnya:

$$\hat{\mu}_{t+1} = B_t \hat{\mathbf{I}}_{t+1} + \alpha_{t+1}.$$

Ini sangat penting.

Ada dua sumber alpha:

factor prediction + idiosyncratic prediction.

J.9. Forecast horizon

Kita harus eksplisit mengenai horizon.

Misalnya:

$$H = 1h.$$

Maka:

$$\hat{\mu}_{i,t}^{(1h)} = E[r_{i,t+1h} \mid \mathbf{F}_t].$$

Untuk horizon lebih panjang:

$$H = 4h, 24h, \dots$$

model harus memiliki target yang berbeda.

J.10. Multi-horizon forecasting

Kita bahkan dapat mendefinisikan:

$$\hat{\mu}_{i,t}^{(H)} = E[r_{i,t+H} | F_t].$$

Kemudian:

$$H \in \{15m, 1h, 4h, 24h\}.$$

Ini sangat berguna untuk menentukan apakah posisi:

- masuk,
- dipertahankan,
- ditutup,
- atau dire-optimalisasi.

J.11. Covariance

Kita memerlukan:

$$\Sigma_t = Cov(\mathbf{r}_{t+1} | F_t).$$

Untuk factor model:

$$\Sigma_t = B_t F_t B_t^T + D_t$$

dengan:

$$F_t = Cov(\mathbf{f}_t)$$

dan:

$$D_t = Cov(\epsilon_t).$$

J.12. Mengapa factor covariance penting?

Jika:

$$BTC$$

dan:

ETH

bergerak bersama, covariance mereka tidak boleh dianggap independen.

Demikian pula:

Gold

dan:

DXY

memiliki hubungan makro yang dapat mempengaruhi portfolio.

Dengan factor model:

Σ

mempunyai struktur yang lebih interpretable.

J.13. Portfolio weights

Definisikan:

$$\mathbf{w}_t = (w_{1,t}, \dots, w_{N,t})^T.$$

Jika long-only fully invested:

$$w_i \geq 0$$

dan:

$$\sum_i w_i = 1.$$

Tetapi untuk sistem trading kita, saya menyarankan **memisahkan asset selection dan position sizing**.

J.14. Asset selection

Definisikan:

$$x_{i,t} \in \{0, 1\}.$$

Dengan:

$$x_{i,t} = 1$$

jika asset i dipilih.

Cardinality constraint:

$$\sum_i x_{i,t} \leq K.$$

Ini adalah salah satu sumber naturally combinatorial optimization.

J.15. Position sizing

Kemudian:

$$w_{i,t} = x_{i,t} z_{i,t}$$

dengan:

$$z_{i,t}$$

sebagai size conditional on selection.

Contohnya:

$$z_i \propto \frac{\hat{\mu}_i}{\hat{\sigma}_i^2}.$$

Atau:

$$z_i \propto \frac{signal_i}{risk_i}.$$

J.16. Risk budget

Kita tidak ingin:

$$w_i$$

ditentukan hanya oleh expected return.

Definisikan portfolio variance:

$$\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w}.$$

Kemudian risk constraint:

$$\mathbf{w}^T \Sigma \mathbf{w} \leq \sigma_{\max}^2.$$

J.17. Factor exposure constraint

Karena kita mengetahui:

$$B,$$

kita dapat membatasi:

$$\mathbf{e}_t = B_t^T \mathbf{w}_t.$$

Misalnya:

$$|e_{DXY}| \leq E_{DXY}^{\max}.$$

atau:

$$|e_{BTC}| \leq E_{BTC}^{\max}.$$

Ini mencegah portfolio diam-diam menjadi taruhan besar terhadap satu factor.

J.18. Portfolio objective

Objective continuous ideal kita:

$$\max_{\mathbf{w}} \quad \boldsymbol{\mu}^T \mathbf{w} - \lambda \mathbf{w}^T \Sigma \mathbf{w} - \kappa T C(\mathbf{w}, \mathbf{w}_{t-1}) - \eta R(\mathbf{w}).$$

Empat komponennya:

return – risk – transaction cost – tail/factor risk.

J.19. Mengubah maximization menjadi minimization

Quantum optimization lebih mudah kita tulis sebagai:

$$\min_{\mathbf{w}} \quad \lambda \mathbf{w}^T \Sigma \mathbf{w} - \boldsymbol{\mu}^T \mathbf{w} + \kappa T C + \eta R.$$

Definisikan:

$$C(\mathbf{w}).$$

Maka:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} C(\mathbf{w}).$$

J.20. Tetapi QAOA membutuhkan binary variables

Maka kita harus melakukan discretization.

Misalnya size:

$$w_i = \delta \sum_{k=0}^{M-1} 2^k b_{ik}$$

dengan:

$$b_{ik} \in \{0, 1\}.$$

Ini adalah **binary encoding**.

J.21. Binary representation

Misalnya:

$$w_i = \delta(b_{i0} + 2b_{i1} + 4b_{i2}).$$

Maka kemungkinan:

$$0, \delta, 2\delta, \dots, 7\delta.$$

Jika:

$$\delta = 0.01,$$

maka:

$$w_i \in \{0, 0.01, \dots, 0.07\}.$$

J.22. Selection + sizing

Kita dapat langsung menggunakan:

$$x_i$$

untuk selection dan:

$$b_{ik}$$

untuk size.

Hubungkan keduanya:

$$w_i \leq w_i^{\max} x_i.$$

Dalam binary formulation, constraint ini dapat dipenalti.

J.23. Constraint penalty

Misalkan:

$$\sum_i w_i = 1.$$

Kita tambahkan:

$$P_{budget} = A \left(\sum_i w_i - 1 \right)^2.$$

Sehingga objective:

$$C(\mathbf{w}) = \lambda \mathbf{w}^T \Sigma \mathbf{w} - \mu^T \mathbf{w} + A (\mathbf{1}^T \mathbf{w} - 1)^2.$$

J.24. Cardinality penalty

Untuk:

$$\sum_i x_i \leq K,$$

kita dapat menggunakan:

$$P_{card} = B \max(0, \sum_i x_i - K)^2.$$

Untuk QUBO murni, kita dapat menggunakan slack variable.

J.25. Slack variable

Ubah:

$$\sum_i x_i \leq K$$

menjadi:

$$\sum_i x_i + s = K.$$

dengan:

$$s \geq 0.$$

Kemudian representasikan s secara binary.

J.26. QUBO final

Secara umum:

$$C(\mathbf{z}) = \mathbf{z}^T Q_t \mathbf{z} + \mathbf{c}_t^T \mathbf{z} + c_0.$$

dengan:

$$\mathbf{z} \in \{0, 1\}^M.$$

Di sinilah seluruh financial problem kita akhirnya masuk ke bentuk combinatorial optimization.

J.27. Dari QUBO ke Ising

Kita menggunakan:

$$z_i = \frac{1 + s_i}{2}$$

dengan:

$$s_i \in \{-1, +1\}.$$

Substitusi ke:

$$C(\mathbf{z}).$$

Maka:

$$C(\mathbf{s}) = C_0 + \sum_i h_i s_i + \sum_{i < j} J_{ij} s_i s_j.$$

J.28. Hamiltonian

Kita kemudian mengganti:

$$s_i \rightarrow Z_i.$$

Sehingga:

$$\hat{H}_C = C_0 I + \sum_i h_i Z_i + \sum_{i < j} J_{ij} Z_i Z_j.$$

Ini lah **cost Hamiltonian**.

J.29. Mengapa Hamiltonian ini sangat penting?

Karena:

$$\hat{H}_C |z\rangle = C(z) |z\rangle.$$

Dengan kata lain setiap computational basis state:

$$|z\rangle$$

merepresentasikan satu portfolio candidate.

Eigenvalue-nya:

$$C(z).$$

Maka:

$$\text{ground state} = \text{optimal portfolio.}$$

J.30. QAOA

Kita mulai dari:

$$|+\rangle^{\otimes M}.$$

Kemudian:

$$|\psi(\gamma, \beta)\rangle = \prod_{\ell=1}^p e^{-i\beta_{\ell} H_M} e^{-i\gamma_{\ell} H_C} |+\rangle^{\otimes M}.$$

J.31. Mixer Hamiltonian

Untuk unconstrained QAOA:

$$H_M = \sum_i X_i.$$

Tetapi nanti untuk constraint yang lebih ketat kita dapat menggunakan:

$$H_M^{\text{constraint}}.$$

agar evolution tidak keluar dari feasible subspace.

Ini akan menjadi pengembangan penting.

J.32. Parameter optimization

Kita mencari:

$$(\gamma^*, \beta^*) = \arg \min_{\gamma, \beta} \langle \psi(\gamma, \beta) | H_C | \psi(\gamma, \beta) \rangle.$$

Objective:

$$E(\gamma, \beta).$$

J.33. Measurement

Setelah optimal:

$$|\psi^*\rangle,$$

kita lakukan measurement.

Probability:

$$p(z) = |\langle z | \psi^* \rangle|^2.$$

Kita mengambil:

$$z^* = \arg \max_z p(z)$$

atau best feasible sample.

J.34. Dari binary solution ke portfolio

Setelah measurement:

$$z^*,$$

decode:

$$z^* \rightarrow x^* \rightarrow w^*.$$

Kemudian:

$$w_t^* = \text{Decode}(\text{Measure}(\text{QAOA}(Q_t))).$$

J.35. Risk-based capital allocation

Di sini kita perlu memisahkan **portfolio optimization** dari **trade risk management**.

Misalnya portfolio menentukan:

$$w_i^*.$$

Tetapi trade-level risk menentukan:

$$R_i.$$

Jika modal:

$$A_t,$$

dan risk budget:

$$\rho A_t,$$

maka:

$$\boxed{R_{max,t} = \rho A_t.}$$

Misalnya:

$$\rho = 0.01.$$

Maka:

$$R_{max} = 1\% \times A_t.$$

J.36. Stop loss

Untuk posisi long:

$$P_{SL} = P_{entry} - d_{SL}.$$

Risk per unit:

$$r_i = P_{entry} - P_{SL}.$$

Position size:

$$\boxed{Q_i = \frac{R_{max}}{r_i}.$$

Dengan demikian:

$$Q_i r_i = R_{max}.$$

Ini adalah mathematical foundation dari ide kita sebelumnya:

setiap trade tetap memiliki risk sekitar \$1.

J.37. Volatility-adjusted stop

Daripada fixed distance:

$$d_{SL} = constant,$$

kita gunakan:

$$d_{SL} = k\sigma_i$$

atau:

$$d_{SL} = kATR_i.$$

Sehingga:

$$Q_i = \frac{R_{max}}{k\sigma_i}.$$

Volatility tinggi:

$$\sigma \uparrow \Rightarrow Q \downarrow .$$

Volatility rendah:

$$\sigma \downarrow \Rightarrow Q \uparrow .$$

Ini secara finansial jauh lebih masuk akal.

J.38. Take profit

Misalnya:

$$P_{TP} = P_{entry} + k_{TP} \sigma_i.$$

Risk-reward ratio:

$$RR = \frac{|P_{TP} - P_{entry}|}{|P_{entry} - P_{SL}|}.$$

Tetapi kita tidak akan membuat:

$$RR = 2$$

secara arbitrer.

Idealnya:

$$TP$$

ditentukan berdasarkan conditional return distribution.

J.39. TP berbasis distribution

Misalkan:

$$R_{i,t+H} \sim F_i.$$

Kita dapat menentukan TP sebagai quantile:

$$TP = Q_q(R_{i,t+H}).$$

Misalnya:

$$q = 0.75.$$

J.40. Dynamic trade management

Setelah posisi terbuka:

$$state_t^{trade} = (P_t, P_{entry}, P_{SL}, P_{TP}, P_{nL_t}, \sigma_t, \mu_t, regime_t).$$

Kita definisikan action:

$$a_t^{trade} \in \{Hold, Close, MoveSL, MoveTP\}.$$

J.41. Floating loss

Jika:

$$PnL_t < 0,$$

kita tidak otomatis close.

Kita evaluasi:

$$P(R_{future} > 0 \mid F_t).$$

Jika probabilitas masih tinggi:

$$P_{win} \geq p_{min},$$

position dapat dipertahankan.

J.42. Floating profit

Jika:

$$PnL_t > 0,$$

kita dapat menghitung:

$$P(R_{future} > 0 \mid F_t).$$

Kemudian:

expected continuation value

dibandingkan dengan:

value of closing.

J.43. Continuation value

Definisikan:

$$V_{hold}(t) = E[P nL_{future} | F_t, Hold].$$

Sedangkan:

$$V_{close}(t) = P nL_t.$$

Maka:

$$\boxed{Hold \text{ jika } V_{hold} > V_{close}.$$

Ini mengubah trailing stop dari rule arbitrer menjadi decision problem.

J.44. Stop-loss adjustment

Jika:

$$P_t > P_{entry}$$

cukup jauh, kita dapat memindahkan SL.

Definisikan:

$$P_{SL,new} = P_t - k\sigma_t.$$

Tetapi harus memenuhi:

$$P_{SL,new} > P_{SL,old}.$$

Dengan demikian stop hanya bergerak ke arah profit protection.

J.45. Dynamic TP

Jika momentum masih kuat:

$$\hat{\mu}_t > 0$$



dan:

$$P(R_{future} > 0)$$

tinggi, TP dapat diperbesar.

Misalnya:

$$TP_{new} = P_t + k_{TP,t}\sigma_t$$

dengan:

$$k_{TP,t} = f(\mu_t, \sigma_t, regime_t, liquidity_t).$$

J.46. Tetapi kita harus mencegah infinite TP expansion

Jika tidak:

$$TP \rightarrow \infty.$$

Maka:

$$k_{TP,t} \leq k_{max}.$$

Selain itu:

$$\frac{dTP}{dt}$$

harus dibatasi.

J.47. Portfolio reoptimization

Pada interval:

$$\tau_r$$

kita melakukan:

$$\mathbf{w}_{t+\tau_r}^* = \text{Optimize}(\mu_{t+\tau_r}, \Sigma_{t+\tau_r}, B_{t+\tau_r}, \text{Regime}_{t+\tau_r}).$$

Jadi portfolio tidak statis.

J.48. Reoptimization trigger

Tidak harus berdasarkan waktu saja.

Kita dapat memiliki:

$$\text{Trigger}_t = \mathbf{1}[D(S_t, S_{t-1}) > \delta].$$

Jika market state berubah cukup besar:

$$\text{Trigger}_t = 1.$$

Maka:

$$\text{Reoptimize.}$$

J.49. Distance antar-regime

Misalnya:

$$D_t = \|\mathbf{s}_t - \mathbf{s}_{t-1}\|_2.$$

Jika:

$$D_t > \delta,$$

kita menganggap market state berubah signifikan.

J.50. Full state vector

Sekarang kita dapat mendefinisikan state:

$$S_t = \begin{bmatrix} \mathbf{r}_t \\ \mathbf{f}_t \\ \hat{\mu}_t \\ \text{diag}(\Sigma_t) \\ \mathbf{B}_t \\ \text{Regime}_t \\ \text{Liquidity}_t \\ \text{Position}_t \\ \text{PnL}_t \end{bmatrix}.$$

Ini merupakan informasi yang digunakan oleh policy.

J.51. Action vector

Definisikan:

$$A_t = (\mathbf{w}_t, \mathbf{Q}_t, \mathbf{P}_{SL,t}, \mathbf{P}_{TP,t}, \mathbf{O}_t).$$

dengan:

- $\mathbf{w}_t$: target portfolio,
 - $\mathbf{Q}_t$: order size,
 - $\mathbf{P}_{SL}$: stop-loss,
 - $\mathbf{P}_{TP}$: take-profit,
 - $\mathbf{O}_t$: order type/status.
-

J.52. State transition

Market bergerak:

$$S_t \rightarrow S_{t+1}.$$

Secara umum:

$$S_{t+1} \sim P(S_{t+1} | S_t, A_t).$$

Ini adalah stochastic transition model.

J.53. Reward

Reward utama:

$$R_t = P n L_t - T C_t - Impact_t - RiskPenalty_t.$$

Misalnya:

$$RiskPenalty_t = \lambda \sigma_{p,t}^2.$$

Maka:

$$R_t = w_t^T r_{t+1} - T C_t - Impact_t - \lambda w_t^T \Sigma_t w_t.$$

J.54. Objective global

Jika seluruh periode:

$$t = 1, \dots, T,$$

maka:

$$J(\pi) = E_{\pi} \left[\sum_{t=1}^T R_t \right].$$

Inilah objective global sistem.

Tetapi implementasi kita tidak harus memakai RL.

Policy:

$$\pi$$

dapat dibentuk secara modular dari:

$$Forecast + Risk + QAOA + Execution + TradeManagement.$$

J.55. Full mathematical pipeline

Sekarang kita dapat menulis sistem kita secara ringkas:

$$F_t \rightarrow S_t$$

kemudian:

$$S_t \rightarrow (\mu_t, \Sigma_t, B_t, Regime_t)$$

kemudian:

$$(\mu_t, \Sigma_t, B_t) \rightarrow Q_t$$

kemudian:

$$Q_t \rightarrow H_{C,t}$$

kemudian:

$$H_{C,t} \xrightarrow{QAOA} z_t^*$$

kemudian:

$$z_t^* \rightarrow w_t^*$$

kemudian:

$$w_t^* \rightarrow Order_t$$

kemudian:

$$Order_t \rightarrow Position_t$$

kemudian:

$$Position_t \rightarrow PnL_{t+1}.$$

J.56. Closed-loop system

Dan yang paling penting:

$$P nL_{t+1}$$

menjadi bagian dari:

$$F_{t+1}.$$


Sehingga:


$$\boxed{F_t \rightarrow A_t \rightarrow P nL_{t+1} \rightarrow F_{t+1} \rightarrow A_{t+1} \rightarrow \cdots}$$

Ini membuat sistem kita **closed-loop**.

J.57. Arsitektur matematis lengkap

Jika kita gambarkan:





J.58. Satu hal penting: QAOA bukan keseluruhan trading system

Ini harus kita pegang.

QAOA hanya berada di:

Optimization Layer.

Bukan:

Prediction Layer.

Bukan:

Execution Layer.

Bukan:

Risk Management Layer.

Sehingga:

$$\text{Trading System} \equiv \text{QAOA.}$$

Lebih tepat:

$$\text{Trading System} = \text{Forecast} + \text{Risk} + \text{Optimization} + \text{Execution} + \text{Control.}$$

QAOA adalah salah satu optimizer yang kita uji di dalamnya.

J.59. Ini juga membuat eksperimen kita jauh lebih bersih

Kita dapat mengganti:

Optimizer

tanpa mengubah komponen lain.

Misalnya:

$$O_1 = \text{Classical}$$

dan:

$$O_2 = \text{QAOA.}$$

Maka:

$$\pi_{\text{classical}} = \text{Risk} \circ \text{Classical} \circ \text{Forecast}$$

sedangkan:

$$\pi_{\text{QAOA}} = \text{Risk} \circ \text{QAOA} \circ \text{Forecast.}$$

Semua komponen lainnya identik.

J.60. Formulasi penelitian paling penting

Kalau seluruh proyek ini akhirnya kita jadikan paper/skripsi yang serius, saya akan merumuskan pertanyaan utamanya sebagai:

Can a quantum approximate optimization procedure provide competitive solutions to dynamic, factor-aware, risk-



Bukan:

"Apakah quantum computing bisa menghasilkan profit?"

Itu pertanyaan yang terlalu sederhana.

J.61. Dan hipotesisnya

Kita dapat memiliki:

H_0

Tidak terdapat perbedaan signifikan antara QAOA dan classical optimization:

$$H_0 : J_{QAOA} = J_{classical}.$$

H_1

QAOA menghasilkan performa yang berbeda:

$$H_1 : J_{QAOA} \neq J_{classical}.$$

Atau jika kita ingin menguji keunggulan:

$$H_1 : J_{QAOA} > J_{classical}.$$

Tetapi kita harus membiarkan data menentukan hasilnya.

J.62. Yang menarik: kita sekarang memiliki tiga "ground truth"

Untuk ukuran kecil:

Exact Optimization

memberikan:

$$C^*.$$

Kemudian:

Classical Approximation

memberikan:

$$C_{\text{classical}}.$$

Dan:

QAOA

memberikan:

$$C_{\text{QAOA}}.$$

Sehingga:

$$C^* \leq C_{\text{classical}}, C_{\text{QAOA}}.$$

Untuk minimization.

Kemudian kita dapat mengukur:

$$\text{Gap}_{\text{classical}} = \frac{C_{\text{classical}} - C^*}{|C^*|}$$

dan:

$$\text{Gap}_{\text{QAOA}} = \frac{C_{\text{QAOA}} - C^*}{|C^*|}.$$

Ini memberi kita **ground-truth mathematical benchmark**.

J.63. Baru setelah itu kita lihat uang

Kemudian:

$$C^* \rightarrow Portfolio^* \rightarrow PnL^*.$$

dan:

$$C_{QAOA} \rightarrow Portfolio_{QAOA} \rightarrow PnL_{QAOA}.$$

Ini memungkinkan kita menjawab pertanyaan menarik:

Apakah improvement dalam optimization objective $\Rightarrow$ improvement dalam financial outcome?

Jawabannya belum tentu.

Dan justru **ketidaksetaraan tersebut merupakan sesuatu yang sangat menarik untuk diteliti.**

J.64. Spesifikasi akhir kita

Jadi secara matematis sistem kita dapat diringkas menjadi:

$$\begin{aligned}
\mathbf{r}_t &= B_t \mathbf{f}_t + \boldsymbol{\epsilon}_t, \\
\hat{\boldsymbol{\mu}}_{t+1} &= E[\mathbf{r}_{t+1} | \mathbf{F}_t], \\
\Sigma_t &= B_t F_t B_t^T + D_t, \\
\mathbf{w}_t^* &= \arg \min_{\mathbf{w}} [\lambda \mathbf{w}^T \Sigma_t \mathbf{w} - \hat{\boldsymbol{\mu}}_{t+1}^T \mathbf{w} + T C_t + R_t], \\
\mathbf{w} &\rightarrow \mathbf{z} \in \{0, 1\}^M, \\
C_t(\mathbf{z}) &= \mathbf{z}^T Q_t \mathbf{z} + \mathbf{c}_t^T \mathbf{z} + c_0, \\
\mathbf{z} &\rightarrow \mathbf{s}, \\
C_t(\mathbf{s}) &= C_0 + \sum_i h_i s_i + \sum_{i < j} J_{ij} s_i s_j, \\
H_{C,t} &= C_0 I + \sum_i h_i Z_i + \sum_{i < j} J_{ij} Z_i Z_j, \\
|\psi_t\rangle &= \prod_{\ell=1}^p e^{-i\beta_{\ell,t} H_M} e^{-i\gamma_{\ell,t} H_{C,t}} |+\rangle^{\otimes M}, \\
(\gamma_t^*, \beta_t^*) &= \arg \min_{\gamma, \beta} \langle H_{C,t} \rangle, \\
\mathbf{z}_t^* &= \text{Measure}(|\psi_t^*\rangle), \\
Q_t^{\text{trade}} &= \frac{R_{\max,t}}{|P_{\text{entry},t} - P_{\text{SL},t}|}, \\
PnL_{t+1} &= \mathbf{w}_t^T \mathbf{r}_{t+1} - T C_t - \text{Impact}_t, \\
\mathbf{F}_{t+1} &= \mathbf{F}_t \cup \{D_{t+1}, PnL_{t+1}\}.
\end{aligned}$$

Ini adalah mathematical backbone dari keseluruhan sistem kita.

J.65. Satu perubahan desain yang saya rekomendasikan

Setelah menyatukan A–J, saya justru ingin sedikit mengubah filosofi sistem kita:

Jangan membuat:

$$QAOA \rightarrow \text{BUY/SELL}$$

secara langsung.

Lebih baik:

$$\text{Market} \rightarrow \text{State} \rightarrow \text{Forecast} \rightarrow \text{Risk} \rightarrow \text{Portfolio} \rightarrow \text{QUBO} \rightarrow \text{QAOA} \rightarrow \text{Target Allocation} \rightarrow \text{Execution}.$$

Dengan begitu **QAOA** menyelesaikan masalah yang memang cocok untuk quantum optimization, yaitu:

discrete, constrained, combinatorial allocation.

Sementara forecasting tetap menggunakan metode statistik/machine learning yang memang cocok untuk forecasting, dan execution tetap menggunakan model microstructure.

Itu membuat keseluruhan sistem jauh lebih masuk akal secara finansial **dan** jauh lebih kuat secara ilmiah.

J.66. Setelah J, kita sebenarnya sudah siap masuk ke implementasi

Tetapi ada satu tahap yang menurut saya **sangat berharga sebelum coding**:

Tahap K — Concrete Market Specification

Di Tahap K kita berhenti berbicara secara abstrak dan menentukan **satu instansiasi nyata** dari seluruh framework.

Misalnya kita menetapkan:

$$Universe = \{BTC, ETH, SOL, \dots\}$$

untuk crypto, lalu:

$$Factors = \{BTC, ETH, DXY, Gold, SPX, VIX\}.$$

Kemudian menentukan secara eksplisit:

- timeframe,
- data source,
- lookback window,
- forecast horizon,
- model forecasting,
- covariance estimator,
- regime model,
- jumlah asset yang boleh dipilih,
- discretization weight,
- seluruh QUBO coefficient,
- penalty coefficient,
- encoding qubit,
- QAOA depth p ,

- mixer,
- optimizer,
- risk budget,
- SL,
- TP,
- trailing logic,
- reoptimization interval,
- transaction cost,
- slippage,
- walk-forward scheme,
- dan **baseline classical optimizer**.

Dengan kata lain:

Tahap J = Mathematical Blueprint

sedangkan:

Tahap K = Numerical/Experimental Specification.

Setelah K selesai, kita dapat membuat **versi 1.0 dari algoritma lengkap**, pseudocode end-to-end, struktur repository, database schema, dan kemudian mulai mengimplementasikannya secara modular tanpa lagi mengubah-ubah definisi matematis di tengah coding.