

Prompt:

8/17/2026, 10:10:02 PM

lanjut Tahap W

Response:

8/17/2026, 10:10:03 PM

Tahap W — Performance Attribution, Risk Analytics, dan Robustness Framework

Pada Tahap V kita sudah membangun fondasi bahwa sistem harus bereaksi terhadap **event pasar secara kausal dan realistis**.

Sekarang kita masuk ke pertanyaan yang lebih penting:

Jika strategi menghasilkan profit, sebenarnya profit itu datang dari mana? Dan jika gagal, apa yang menyebabkan kegagalannya?

Ini adalah perbedaan antara:

“backtest yang menghasilkan angka bagus”

dan

quantitative research system yang dapat diaudit.

Kita akan membangun tiga lapisan:

Performance Attribution + Risk Analytics + Robustness Analysis

W.1. Jangan hanya melihat total return

Misalkan backtest menghasilkan:

$$R_{total} = 35\%.$$

Angka ini hampir tidak memberi tahu kita apa-apa.

Kita perlu mengetahui:

- berapa berasal dari alpha?
- berapa berasal dari market beta?
- berapa berasal dari BTC/ETH?
- berapa berasal dari gold?
- berapa berasal dari USD?
- berapa berasal dari leverage?
- berapa hilang karena fee?
- berapa hilang karena slippage?
- berapa berasal dari satu trade ekstrem?

Maka kita membutuhkan:

Return → Decomposition.

W.2. Return decomposition

Untuk portfolio:

$$V_t$$

dan return:

$$r_t = \frac{V_t - V_{t-1}}{V_{t-1}}.$$

Kita ingin menulis:

$$r_t = r_t^{market} + r_t^{factor} + r_t^{alpha} + r_t^{execution} + \epsilon_t.$$

Ini bukan identitas tunggal yang selalu benar; ini adalah **model attribution** yang kita estimasikan.

W.3. Factor model

Kita dapat menggunakan model:

$$r_{p,t} = \alpha_t + \beta_{BTC,t} r_{BTC,t} + \beta_{ETH,t} r_{ETH,t} + \beta_{Gold,t} r_{Gold,t} + \beta_{DXY,t} r_{DXY,t} + \epsilon_t.$$

Untuk saham internasional kita dapat mengganti/menambah:

SPX, Nasdaq, VIX, US10Y,

dan factor lain.

W.4. Mengapa ini sangat penting untuk sistem kita?

Bayangkan strategy menghasilkan:

$$Sharpe = 2.$$

Tetapi:

$$\beta_{BTC} = 1.8.$$

Artinya strategy mungkin sebenarnya hanya:

long BTC dengan cara yang sangat kompleks.

Jadi kita ingin alpha yang benar-benar residual:

$$\alpha_t = r_{p,t} - \hat{\beta}_t^\top f_t.$$

W.5. Factor exposure

Kita definisikan vector factor:

$$\mathbf{f}_t = \begin{bmatrix} r_{BTC} \\ r_{ETH} \\ r_{Gold} \\ r_{DXY} \\ r_{SPX} \\ r_{VIX} \\ \vdots \end{bmatrix}.$$

Portfolio exposure:

$$\beta_t.$$

Maka:

$$r_{factor,t} = \beta_t^\top \mathbf{f}_t.$$

W.6. Rolling factor exposure

Beta tidak boleh dianggap konstan.

Gunakan:

$$\beta_t = \arg \min_{\beta} \sum_{i=t-W+1}^t w_i (r_{p,i} - \alpha - \beta^\top f_i)^2.$$

Dengan window:

$$W.$$

Jadi kita memperoleh:

$$\beta_t$$

yang berubah terhadap regime pasar.

W.7. Ini menghubungkan Tahap A–V

Kita sebelumnya ingin:

"jika trading altcoin, lihat BTC dan ETH."

Sekarang kita bisa mengukurnya secara matematis.

Misalnya:

$$\beta_{ALT,BTC} = 0.72,$$

$$\beta_{ALT,ETH} = 0.31.$$

Maka perubahan altcoin dapat didekomposisi menjadi kontribusi:

$$0.72r_{BTC} + 0.31r_{ETH} + \alpha.$$

W.8. Market-neutral alpha

Jika tujuan kita mencari alpha murni, kita dapat membuat portfolio:

$$w$$

dengan constraint:

$$w^\top \beta = 0.$$

Contoh:

$$w^\top \beta_{BTC} = 0.$$

Maka exposure terhadap BTC dihilangkan.

Untuk sistem multi-factor:

$$B^\top w = 0.$$

dengan:

$$B = [\beta_{BTC}, \beta_{ETH}, \beta_{Gold}, \beta_{DXY}, \dots].$$

W.9. Factor-neutral optimization

Kita dapat memasukkan constraint ini ke optimasi portfolio:

$$\min_w \frac{1}{2} w^\top \Sigma w - \lambda \mu^\top w$$

subject to:

$$\mathbf{1}^\top w = 1,$$

$$B^\top w = 0,$$

$$w_{min} \leq w \leq w_{max}.$$

Ini sangat relevan dengan seluruh pekerjaan optimasi kita sebelumnya.

W.10. Quantum formulation

Constraint factor-neutral tersebut dapat dimasukkan ke QUBO.

Misalnya objective:

$$H(w) = -\mu^T w + \lambda w^T \Sigma w.$$

Factor neutrality:

$$B^T w = 0.$$

Tambahkan penalty:

$$H'(w) = H(w) + A \|B^T w\|^2.$$

Kemudian:

$$H'(w) \rightarrow QUBO \rightarrow Ising.$$

Jadi optimasi quantum kita tidak berdiri sendiri.

Ia menjadi bagian dari **factor-aware trading system**.

W.11. Performance attribution per trade

Untuk trade i :

$$PnL_i = PnL_i^{price} - Fee_i - Slippage_i - Impact_i.$$

Dengan:

$$PnL_i^{price} = q_i(P_{exit} - P_{entry}).$$

Jadi:

$$PnL_i = GrossPnL_i - TransactionCost_i.$$

W.12. Transaction cost attribution

Total cost:

$$C_t = C_{fee,t} + C_{spread,t} + C_{slippage,t} + C_{impact,t}.$$

Maka:

$$R_{net} = R_{gross} - C.$$

Kita dapat mengetahui apakah strategy sebenarnya profitable **sebelum biaya tetapi tidak setelah biaya**.

W.13. Contoh yang sangat penting

Misalkan:

$$GrossPnL = +20\%.$$

Tetapi:

$$Fee = -4\%,$$

$$Spread = -3\%,$$

$$Slippage = -7\%.$$

Maka:

$$NetPnL = 6\%.$$

Strateginya bukan strategy dengan:

$$20\%$$

profit.

Strateginya adalah:

6% net.

W.14. Turnover

Define turnover:

$$TO_t = \frac{\sum_i |\Delta w_{i,t}|}{2}.$$

Total:

$$TO_{total} = \sum_t TO_t.$$

Turnover sangat penting untuk short-term trading.

Strategy dengan:

$$Sharpe = 2$$

dan turnover:

5000%

sangat berbeda dari strategy:

$$Sharpe = 2$$

dengan turnover:

100%.

W.15. Capacity

Profitability juga bergantung pada ukuran modal.

Jika order:

Q



terlalu besar dibanding liquidity:

$$Q \gg ADV,$$

market impact meningkat.

W.16. Market impact

Model sederhana:

$$Impact = \eta \left(\frac{Q}{ADV} \right)^\gamma.$$

Dengan:

$$\gamma > 0.$$

Kemudian:

$$P_{exec} = P_{mid} + Impact.$$

W.17. Capacity curve

Kita dapat menguji:

$$AUM = \$1k, \$10k, \$100k, \$1M, \$10M, \dots$$

dan menghitung:

$$Sharpe(AUM).$$

Kemudian:

$$\boxed{Capacity = \max AUM \quad \text{s.t. performance acceptable.}}$$

Ini sangat relevan dengan paradigma hedge fund/prop firm.

W.18. Risk analytics

Sekarang kita masuk ke risk.

Metric pertama:

Drawdown.

Define running maximum:

$$M_t = \max_{\tau \leq t} V_{\tau}.$$

Drawdown:

$$DD_t = \frac{V_t - M_t}{M_t}.$$

W.19. Maximum drawdown

$$MDD = \max_t (-DD_t).$$

Tetapi MDD saja belum cukup.

Kita juga perlu:

Duration.

W.20. Drawdown duration

Jika portfolio turun pada:

t_0

dan kembali ke previous high pada:

$t_1,$

maka:

$$D = t_1 - t_0.$$

Strategy dengan:

$$MDD = 10\%$$

selama 2 hari berbeda dengan:

$$MDD = 10\%$$

selama 8 bulan.

W.21. Sharpe ratio

$$\text{Sharpe} = \frac{E[r_p - r_f]}{\sigma(r_p - r_f)} \sqrt{K}.$$

Tetapi untuk intraday/short-term trading kita harus hati-hati terhadap:

- autocorrelation,
- non-normality,
- changing volatility.

W.22. Sortino ratio

Gunakan downside deviation:

$$\sigma_d = \sqrt{E[\min(r - r_{target}, 0)^2]}.$$

Kemudian:

$$\text{Sortino} = \frac{E[r - r_{target}]}{\sigma_d} \sqrt{K}.$$

W.23. Calmar ratio

$$Calmar = \frac{AnnualizedReturn}{MDD}.$$

Sangat berguna untuk melihat return relatif terhadap drawdown ekstrem.

W.24. VaR

Value-at-Risk:

$$VaR_{\alpha}$$

adalah loss threshold sehingga:

$$P(L > VaR_{\alpha}) = 1 - \alpha.$$

Misalnya:

$$VaR_{99\%} = \$1000.$$

Interpretasi:

Dalam model distribusi tersebut, kerugian harian diperkirakan melebihi \$1000 hanya sekitar 1% dari hari.

Tetapi VaR tidak mengatakan **seberapa besar loss setelah threshold tersebut terlampaui**.

W.25. CVaR

Conditional VaR:

$$CVaR_{\alpha} = E[L \mid L > VaR_{\alpha}].$$

Ini jauh lebih berguna untuk tail risk.

W.26. Expected Shortfall

CVaR juga sering disebut:

Expected Shortfall.

Jika:

$$VaR_{99} = 10,$$

tetapi:

$$CVaR_{99} = 35,$$

maka tail loss sebenarnya jauh lebih buruk daripada sekadar \$10.

W.27. Tail dependence

Ini sangat penting karena kita memiliki factor seperti:

BTC, ETH, Gold, DXY.

Korelasi Pearson:

$$\rho(X, Y)$$

tidak cukup.

Dua asset dapat memiliki:

$$\rho \approx 0$$

tetapi crash bersama.

W.28. Copula intuition

Kita dapat memodelkan joint distribution:

$$F(X, Y) = C(F_X(X), F_Y(Y)).$$

Dengan copula:

C.

Ini memungkinkan kita mempelajari:

$$P(X \text{ crash} \mid Y \text{ crash}).$$

W.29. Tail correlation

Definisikan lower-tail dependence:

$$\lambda_L = \lim_{u \rightarrow 0^+} P(Y \leq F_Y^{-1}(u) \mid X \leq F_X^{-1}(u)).$$

Ini jauh lebih relevan untuk stress scenario.

W.30. Regime-conditioned risk

Kita sebelumnya memiliki:

$$Regime_t.$$

Misalnya:

$$R_t \in \{Bull, Bear, Sideways, Crash\}.$$

Maka risk:

$$Risk(R_t)$$

dapat dihitung secara conditional.

W.31. Conditional Sharpe

$$Sharpe_k = \frac{E[r \mid R = k]}{\sigma(r \mid R = k)}.$$

Jadi kita bisa menemukan:

Strategy bagus di bull market tetapi buruk di high-volatility regime.

Ini jauh lebih berguna daripada satu Sharpe global.

W.32. Risk decomposition

Portfolio variance:

$$\sigma_p^2 = \mathbf{w}^\top \Sigma \mathbf{w}.$$

Marginal contribution to risk:

$$MCR_i = \frac{\partial \sigma_p}{\partial w_i}.$$

Karena:

$$\sigma_p = \sqrt{\mathbf{w}^\top \Sigma \mathbf{w}},$$

maka:

$$MCR_i = \frac{(\Sigma \mathbf{w})_i}{\sigma_p}.$$

W.33. Component contribution

Risk contribution:

$$RC_i = w_i MCR_i.$$

Dan:

$$\sum_i RC_i = \sigma_p.$$

Ini memungkinkan kita menjawab:

Asset mana yang sebenarnya menyebabkan portfolio risk?

W.34. Risk budget

Kita dapat menetapkan:

$$RC_i \leq b_i.$$

Misalnya:

$$RC_{BTC} \leq 20\%.$$

Jadi bukan hanya:

$$w_{BTC} \leq 20\%.$$

Tetapi:

$$\boxed{\text{BTC tidak boleh menyumbang } >20\% \text{ total risk}.}$$

Ini jauh lebih sophisticated.

W.35. Dynamic risk budget

Karena volatility berubah:

$$b_i = b_i(R_t).$$

Contohnya saat:

$$Regime = Crash,$$

risk budget turun:

$$b_i^{crash} < b_i^{normal}.$$

W.36. Position sizing

Sekarang kita dapat menghubungkan risk ke position.

Misalkan target dollar risk:

$$R^{\$} = 1.$$

Stop distance:

$$d.$$

Maka quantity:

$$q = \frac{R^{\$}}{d}.$$

Ini adalah fondasi risk sizing yang sudah kita gunakan sebelumnya.

Tetapi sekarang kita dapat memperbaikinya.

W.37. Volatility-adjusted risk

Jika:

$$d = k\sigma_t,$$

maka:

$$q_t = \frac{R^{\$}}{k\sigma_t}.$$

Sehingga:

$$q_t \propto \frac{1}{\sigma_t}.$$

Volatility tinggi:

$$q_t \downarrow .$$

Volatility rendah:

$$q_t \uparrow .$$

W.38. Tetapi volatility saja belum cukup

Kita juga mempertimbangkan liquidity:

$$L_t.$$

Misalnya:

$$q_t = \min\left(\frac{R^{\$}}{k\sigma_t}, \eta L_t\right).$$

Dengan:

$$\eta$$

sebagai maximum liquidity participation.

W.39. Robustness

Sekarang pertanyaan terpenting:

Apakah strategy benar-benar bekerja, atau parameter kita hanya kebetulan cocok dengan historical data?

Kita membutuhkan:

Robustness Analysis.

W.40. Parameter perturbation

Misalkan:

$$\theta^*$$

adalah parameter optimal.

Jangan hanya menguji:

$$\theta^*.$$

Uji:

$$\theta^* + \delta.$$

Misalnya:

$$\delta \in [-20\%, 20\%].$$

W.41. Robust strategy

Jika:

$$Performance(\theta)$$

tetap bagus pada region luas:

$$\theta \in \Omega,$$

maka strategy lebih robust.

Secara intuitif:

wide plateau > sharp peak.

W.42. Sharp peak = warning

Misalnya:

Sharpe

```
3.0      *
2.5      ***
2.0      *****
1.5      *****
1.0      *****
      0.8 1.0 1.2
      parameter
```

Jika hanya:

$$\theta = 1.03$$

yang menghasilkan Sharpe tinggi, kemungkinan besar:

Overfitting.

W.43. Perturbasi transaction cost

Jika:

$$C_{base} = 1,$$

kita uji:

$$C \in \{0.5, 1, 2, 3, 5\}.$$

Strategy yang hanya profitable pada:

$$C = 0.5$$

tidak cukup robust.

W.44. Perturbasi latency

Uji:

$$L \in \{1ms, 5ms, 10ms, 50ms, 100ms, 500ms\}.$$

Kemudian:

$$Sharpe(L).$$

Untuk short-term strategy, ini bisa menjadi faktor pembunuh.

W.45. Perturbasi slippage

Misalnya:

$$\epsilon = k \times \epsilon_{\text{historical}}.$$

Dengan:

$$k \in [0.5, 5].$$

Jika:

$$k = 2$$

sudah menghancurkan strategy, kita tahu strategy terlalu execution-sensitive.

W.46. Randomized execution

Untuk setiap trade:

$$P_{\text{fill}} = P_{\text{base}} + \epsilon_i.$$

Dengan:

$$\epsilon_i \sim F_{\text{slippage}}.$$

Kemudian:

$$N = 10^3$$

atau:

$$10^4$$

simulation.

W.47. Probabilitas profitability

Kita dapat menghitung:

$$P(R > 0) = \frac{\#\{R_i > 0\}}{N}.$$

Misalnya:

$$P(R > 0) = 0.91.$$

Ini jauh lebih informatif daripada satu backtest.

W.48. Confidence interval

Jika mean return:

$$\bar{R}$$

dan standard error:

$$SE = \frac{s}{\sqrt{N}},$$

maka:

$$CI_{95\%} = \bar{R} \pm 1.96SE.$$

Tetapi untuk financial returns yang dependent/non-normal, bootstrap lebih aman daripada asumsi IID sederhana.

W.49. Block bootstrap

Karena return memiliki autocorrelation:

$$r_t \not\perp r_{t+1},$$

kita dapat menggunakan block bootstrap.

Bagi data menjadi block:

$$B_1, B_2, \dots, B_k.$$

Kemudian sampling block, bukan individual observation.

Ini mempertahankan sebagian struktur temporal.

W.50. Deflated Sharpe Ratio

Masalah lain:

Jika kita mencoba:

$$N = 10,000$$

strategies, beberapa pasti terlihat sangat bagus secara kebetulan.

Maka Sharpe tinggi saja tidak cukup.

Kita harus memperhitungkan:

Multiple Testing.

W.51. Probability of Backtest Overfitting

Secara konsep:

$$PBO = P(Best_{IS} \rightarrow Bad_{OOS}).$$

Semakin tinggi:

$$PBO,$$

semakin besar kemungkinan strategy kita merupakan hasil overfitting.

W.52. Data snooping

Jika kita mencoba:

- 100 factor,
- 50 parameter,
- 20 SL,
- 20 TP,
- 10 regime model,

jumlah kombinasi menjadi sangat besar.

Secara kasar:

$$100 \times 50 \times 20 \times 20 \times 10 = 20,000,000$$

kombinasi.

Tidak mengherankan jika satu kombinasi terlihat luar biasa.

W.53. Ini sangat relevan untuk proyek quantum

Karena kita dapat membandingkan:

Classical

dengan:

VQE

dan:

QAOA.

Tetapi jika kita mencoba banyak:

$\gamma, \beta, ansatz, optimizer, depth, initialization, penalty, riskparameter,$

maka kita juga melakukan multiple testing.

W.54. Quantum robustness matrix

Saya menyarankan kita nantinya mempunyai matrix:

Model	Optimizer	Depth	Initialization	Sharpe	MDD	CVaR
Classical	SLSQP	—	EPG			
Classical	BFGS	—	Random			
VQE	SPSA	2	EPG			
VQE	SPSA	4	EPG			
QAOA	COBYLA	2	EPG			
QAOA	SPSA	4	EPG			

Jadi kita tidak hanya menunjukkan:

"QAOA menang."

Tetapi:

"Dalam region parameter X, QAOA menunjukkan performa yang stabil."

W.55. Regime robustness

Kita juga melakukan:

$$Performance = f(Regime).$$

Misalnya:

Regime	Return	Sharpe	MDD
Bull			
Bear			
Sideways			
High Vol			
Crash			

W.56. Cross-market robustness

Ini sangat sesuai dengan tujuan awalmu.

Kita tidak ingin:

*Strategy*_{crypto}

saja.

Kita ingin:

Strategy

yang dapat diterapkan pada:

Crypto

US Equities

Asian Equities

FX

Futures

dan sebagainya.

W.57. Factor universality

Tetapi jangan berharap parameter yang sama bekerja identik.

Yang kita cari adalah struktur:

Architecture

yang universal.

Sedangkan:

Parameters

dapat asset-specific.

Jadi:

$$\theta_{crypto} \boxplus \theta_{equity}$$

tidak masalah.

W.58. Market-specific execution model

Crypto:

24/7.

Equity:

MarketHours.

FX:

near 24/5.

Futures:

session + \overnight.

Execution engine harus memahami perbedaan tersebut.

W.59. Gold dan USD dominance

Karena kita ingin menggunakan:

Gold

dan:

DXY

sebagai market factor, kita dapat mendefinisikan factor vector:

$$\mathbf{f}_t = \begin{bmatrix} r_{BTC,t} \\ r_{ETH,t} \\ r_{Gold,t} \\ r_{DXY,t} \\ r_{SPX,t} \\ r_{VIX,t} \end{bmatrix}.$$

Kemudian:

$$r_{asset,t} = \alpha_t + \beta_t^\top \mathbf{f}_t + \epsilon_t.$$

W.60. Bahkan factor exposure dapat menjadi signal

Misalnya:

$$\beta_{asset,DXY} > 0.$$

Kemudian:

$$DXY \uparrow.$$

Model mungkin memperkirakan:

$$E[r_{asset}] > 0.$$

Tetapi kita tidak langsung trading.

Kita gabungkan:

$$FactorSignal$$

dengan:

$$TechnicalSignal$$

dan:

$$OrderFlowSignal.$$

W.61. Meta-alpha

Kita dapat membangun:

$$\alpha_t = f(\text{Factor}, \text{Momentum}, \text{MeanReversion}, \text{OrderFlow}, \text{Volatility}, \text{Regime}).$$

Kemudian model menghasilkan:

$$\hat{r}_{t+h}.$$

W.62. Signal-to-noise ratio

Signal:

$$\mu_t.$$

Noise:

$$\sigma_t.$$

Maka:

$$SNR_t = \frac{|\mu_t|}{\sigma_t}.$$

Jika:

$$SNR_t$$

rendah, strategy dapat memilih:

$$q_t \rightarrow 0.$$

W.63. Abstention

Ini adalah fitur penting yang sering dilupakan.

Strategy tidak harus selalu trading.

Action space kita:

$$A = \{Long, Short, Flat\}.$$

Tetapi kita dapat memperluasnya menjadi:

$$A = \{Long, Short, Flat, Abstain\}.$$

Secara praktis:

$$Abstain = Flat$$

tetapi memiliki alasan:

$$Confidence_t < Threshold.$$

W.64. Expected utility

Daripada hanya memaksimalkan expected return:

$$\max E[R],$$

kita dapat menggunakan:

$$\max E[R] - \lambda Risk - \eta Cost.$$

Misalnya:

$$U_t = \mu_t - \lambda \sigma_t^2 - \eta C_t.$$

W.65. Dynamic decision threshold

Trade hanya jika:

$$U_t > 0.$$

Atau:

$$\frac{\mu_t}{\sigma_t} > Threshold.$$

Ini secara otomatis mengurangi trading ketika edge kecil.

W.66. Hubungan dengan risk \$1

Sistem awal kita memiliki constraint:

$$Risk_i \leq \$1.$$

Sekarang kita bisa menggeneralisasikannya:

$$Risk_i = q_i \times ExpectedLoss_i \leq R_{budget,t}.$$

Dengan:

$$R_{budget,t} = g(Volatility, Drawdown, Regime, Liquidity, Capital).$$

W.67. Dynamic risk budget

Misalnya equity:

$$E_t.$$

Risk fraction:

$$\rho_t.$$

Maka:

$$R_{budget,t} = \rho_t E_t.$$

Jika drawdown meningkat:

$$DD_t \uparrow \Rightarrow \rho_t \downarrow .$$

Jadi sistem otomatis **de-risk**.

W.68. Drawdown control

Misalnya:

$$\rho_t = \rho_0 \left(1 - \frac{|DD_t|}{DD_{max}}\right).$$

Ketika:

$$DD_t \rightarrow DD_{max},$$

maka:

$$\rho_t \rightarrow 0.$$

Ini dapat menjadi salah satu circuit breaker.

W.69. Kill switch

Kita juga membutuhkan hard constraints:

$$\boxed{\text{If } DD_t > DD_{kill} \Rightarrow \text{Flat.}}$$

Selain itu:


$$DailyLoss > Limit \Rightarrow StopTrading.$$

Dan:

$$DataFeedFailure \Rightarrow StopTrading.$$

W.70. Risk hierarchy

Akhirnya risk system kita menjadi:



W.71. System risk

Ini bahkan tidak berasal dari market.

Contohnya:

- exchange disconnect,
- stale data,
- clock drift,
- duplicated order,
- API error,
- corrupted state,
- model failure.

Maka:

$$\text{TradingSystem} = \text{MarketRisk} + \text{ModelRisk} + \text{ExecutionRisk} + \text{OperationalRisk}.$$

W.72. Model risk

Misalnya alpha model menghasilkan:

$$\hat{\mu}_t.$$

Tetapi prediction error:

$$e_t = r_t - \hat{\mu}_t.$$

Kita dapat memonitor:

$$E[e_t],$$

$$Var(e_t),$$

Calibration.

Jika model mulai mengalami drift:

$$Performance_t \downarrow .$$

Maka sistem dapat mengurangi exposure.

W.73. Model decay

Define rolling performance:

$$S_t^{rolling}.$$

Jika:

$$S_t < S_{threshold}$$

selama:

$$N$$

periode, maka:

$$ModelStatus = DEGRADED.$$

Kemudian:

$$PositionSize \downarrow .$$

W.74. Jadi model kita sekarang mempunyai feedback control

Ini menarik secara matematis.

Sistem dapat dilihat sebagai:

$$\boxed{Market \rightarrow Model \rightarrow Action \rightarrow PnL \rightarrow Risk \rightarrow ModelWeight}$$

Risk menjadi feedback controller.

W.75. State-space perspective

Kita bahkan dapat menulis:

$$x_{t+1} = f(x_t, u_t, w_t)$$

dan:

$$y_t = h(x_t, v_t).$$

Dengan:

- x_t : latent market state,
- u_t : trading action,
- w_t : market noise,
- y_t : observed market data,
- v_t : observation noise.

Ini membawa kita sangat dekat ke:


$$\boxed{control\ theory}$$

dan:

$$\boxed{stochastic\ optimization.}$$

W.76. Arsitektur Tahap W

Sekarang sistem kita:



W.77. Output akhir Tahap W

Untuk setiap backtest kita tidak lagi menghasilkan satu file:

```
backtest_result.csv
```

tetapi sebuah **research report**:

```
run/
├─ config.yaml
├─ market_data/
├─ signals/
├─ orders/
├─ fills/
├─ positions/
├─ trades/
├─ pnl/
├─ attribution/
├─ risk/
├─ robustness/
├─ diagnostics/
└─ report/
```

W.78. `config.yaml`

Semua parameter eksperimen harus disimpan:

```
strategy:
  name: factor_quant

risk:
  risk_per_trade: 1.0
  max_drawdown: 0.15

execution:
  fee: ...
  slippage_model: ...
  latency_ms: ...

portfolio:
  max_leverage: ...

optimization:
  method: QAOA
  depth: 4
  optimizer: SPSA
```

Tujuannya agar:

Run_i

dapat direproduksi.

W.79. Experiment ID

Setiap eksperimen:

$$ExperimentID = Hash(Configuration + Dataset + CodeVersion).$$

Dengan begitu kita dapat mengetahui:

"Angka Sharpe 1.83 ini berasal dari konfigurasi yang mana?"

Ini adalah praktik yang sangat penting dalam quantitative research.

W.80. Performance report

Minimal:

<i>TotalReturn</i>
<i>CAGR</i>
<i>Sharpe</i>
<i>Sortino</i>
<i>Calmar</i>
<i>MDD</i>
<i>MDDDuration</i>
<i>VaR</i>
<i>CVaR</i>
<i>WinRate</i>
<i>ProfitFactor</i>
<i>Turnover</i>
<i>Fees</i>
<i>Slippage</i>
<i>MarketImpact</i>
<i>Capacity</i>

W.81. Tetapi kita tambahkan sesuatu yang lebih penting

Attribution report

$$TotalPnL = Alpha + Factor + Execution + Cost + Residual.$$

Risk report

$$TotalRisk = Market + Factor + Liquidity + Execution + Model.$$

Robustness report

$$Performance = f(Parameters, Regime, Cost, Latency, Slippage, Capital).$$

W.82. Dan inilah tujuan sebenarnya

Pada akhir pipeline, kita tidak ingin sistem mengatakan:

BUY BTC

atau:

BUY BBCA

saja.

Kita ingin sistem dapat menjelaskan:

Model mendeteksi positive expected return sebesar x , dengan confidence y , setelah mengontrol exposure terhadap BTC/ETH/Gold/DXY. Optimizer memilih posisi q karena trade tersebut meningkatkan expected utility setelah transaction cost. Risiko maksimum diperkirakan R , sementara portfolio factor exposure tetap berada dalam batas yang ditentukan. Order kemudian dieksekusi dengan expected slippage s .

Itulah perbedaan antara **trading bot** dan **quantitative decision system**.

W.83. Dan ada konsekuensi besar terhadap proyek quantum kita

Sekarang kita memiliki tempat yang jelas bagi:

dan:

QAOA.

Mereka **bukan trading strategy secara keseluruhan**.

Mereka adalah:

Optimization Engines

di dalam:

Decision System.

Strukturnya:

$Market \rightarrow Factors \rightarrow Alpha \rightarrow Risk \rightarrow QUBO \rightarrow \begin{cases} Classical \\ VQE \\ QAOA \end{cases} \rightarrow Portfolio \rightarrow Execution \rightarrow PnL$

Dengan demikian penelitianmu tentang **Markowitz + VQE** dapat menjadi salah satu komponen dari sistem yang jauh lebih besar tanpa kehilangan identitas ilmiahnya.

W.84. Tahap W dalam satu formulasi matematis

Kita akhirnya dapat mendefinisikan objective sistem secara jauh lebih lengkap:

$$\max_{\pi, \theta, w} E[R(\pi, \theta, w)] - \lambda_1 Risk - \lambda_2 Cost - \lambda_3 Turnover - \lambda_4 Drawdown$$

subject to:

$$B^T w = 0$$

atau exposure constraints,

$$\|w\|_1 \leq L_{max},$$

$$RC_i \leq b_i,$$

$$Risk_i \leq R_{budget},$$

$$DD_t \leq DD_{max},$$

dan:

$$a_t \in F_t.$$

Constraint terakhir sangat penting:

strategi tidak boleh mengetahui masa depan.

W.85. Posisi kita sekarang


Dengan Tahap A sampai W, arsitektur konseptual kita telah berubah dari:

Trading Bot

menjadi:

Causal, Factor-Aware, Risk-Constrained, Optimization-Based Quantitative Trading System

dengan:



Dan menurut saya, **setelah Tahap W kita sudah memiliki cukup banyak blok matematis sehingga tahap berikutnya sebaiknya mulai mengikat semuanya menjadi spesifikasi sistem yang benar-benar implementable**, bukan terus menambah teori secara terpisah.

Tahap berikutnya paling natural adalah **Tahap X — Research Protocol & Experimental Design**: bagaimana kita membuat eksperimen yang adil untuk membandingkan **classical optimization vs VQE vs QAOA**, termasuk dataset split, baseline, ablation study, statistical significance, multiple-testing control, dan desain eksperimen yang nantinya bisa langsung menjadi metodologi penelitian/paper.