

Prompt:

8/17/2026, 10:14:34 PM

lanjut Tahap AA

Response:

8/17/2026, 10:14:35 PM

Tahap AA — Dataset, Asset Universe, Timeframe, dan Walk-Forward Experiment

Kita sekarang masuk ke bagian yang menurutku **sangat penting**: mengubah mathematical spine pada Tahap Z menjadi **eksperimen yang bisa direproduksi**.

Kalau Tahap Z menjawab:

"Apa sistem matematis kita?"

maka Tahap AA menjawab:

"Data apa yang boleh dilihat model, kapan model boleh melihatnya, bagaimana data antar-pasar diselaraskan, dan bagaimana kita menguji model tanpa kebocoran informasi?"

Saya akan cukup ketat di sini, karena kesalahan pada tahap ini dapat membuat seluruh hasil VQE/QAOA terlihat bagus padahal sebenarnya terkena **look-ahead bias**.

AA.1. Prinsip dasar: waktu adalah dimensi utama

Misalkan pada waktu t , sistem membuat keputusan.

Kita definisikan informasi yang tersedia:

$$F_t = \sigma(D_\tau : \tau \leq t)$$

di mana:

- D_τ = seluruh data yang benar-benar tersedia pada waktu τ ,
- F_t = information set pada waktu t .

Model hanya boleh menghasilkan:

$$a_t = f(F_t)$$

dan **tidak boleh** menggunakan:

$$D_{t+\Delta t}.$$

Jadi:

$$\text{Decision at } t \Rightarrow \text{uses information available at } t.$$

Ini akan menjadi hukum utama backtest kita.

AA.2. Kita tidak membuat satu dataset

Sistem kita sebenarnya membutuhkan **empat jenis data**.

1. Market data

$$D_t^{market}$$

berisi OHLCV dan order book.

2. Factor data

$$D_t^{factor}$$

berisi BTC, ETH, DXY, Gold, SPX, VIX, dan sebagainya.

3. Execution data

$$D_t^{execution}$$

berisi spread, bid/ask, depth, fill, slippage.

4. Portfolio state

$$D_t^{portfolio}$$

berisi posisi yang sedang terbuka, cash, exposure, entry, SL, TP.

Jadi:

$$D_t = \{D_t^{market}, D_t^{factor}, D_t^{execution}, D_t^{portfolio}\}.$$

AA.3. Asset universe

Saya ingin membagi universe menjadi tiga kelompok.

A. Target assets

Ini adalah asset yang boleh dipilih optimizer.

Misalnya crypto:

$$A_T^{crypto} = \{SOL, XRP, ADA, DOGE, AVAX, LINK\}.$$

Untuk saham:

$$A_T^{equity} = \{AAPL, MSFT, NVDA, AMZN, META\}.$$

B. Market factors

Crypto:

$$A_M^{crypto} = \{BTC, ETH\}.$$

Saham:

$$A_M^{equity} = \{SPX, NDX\}.$$

C. Macro factors

$$F = \{DXY, Gold, VIX, US10Y\}.$$

Sehingga sistem dapat mengetahui misalnya:

$$ALT \leftarrow BTC, ETH$$

dan:

$$\text{Equity} \leftarrow SPX, NDX, DXY, Gold, VIX, US10Y.$$

AA.4. Jangan mencampur crypto dan saham terlebih dahulu

Walaupun tujuan akhirnya adalah satu framework universal, eksperimen pertama sebaiknya:

Crypto System

dan:

Equity System

secara terpisah.

Alasannya sederhana.

Crypto:

24/7.

Saham:

market session.

Kalau langsung dicampur, kita akan memiliki masalah:

- timezone,
- market holiday,
- overnight gap,
- asynchronous information,
- different liquidity,
- different trading hours.

Jadi arsitektur sama, dataset berbeda.

AA.5. Timeframe utama

Saya menyarankan:

$$\text{Decision timeframe} = 1h.$$

Kenapa 1 jam?

Karena kita ingin short-term trading tetapi tidak terlalu mikro.

Jika menggunakan:

$1m$

atau:

$5m,$

market microstructure menjadi jauh lebih dominan.

Sementara:

$1h$

masih cukup cepat untuk:

- intraday,
- swing pendek,
- dynamic TP/SL,
- regime adaptation.

AA.6. Multi-resolution architecture

Namun bukan berarti seluruh sistem hanya menggunakan 1h.

Kita gunakan:

$$1h = \text{decision layer}$$

dan:

$$1m/5m = \text{execution layer}.$$

Misalnya:

1h data



Prediction



QUBO



Trade decision



1m data



Order execution

AA.7. Mengapa ini penting?

Misalkan model menghasilkan:

$$P_t = 100$$

dan ingin membeli pada:

$$P_{entry} = 99.5.$$

Jika candle 1h memiliki:

$$L_t = 99$$

maka kita tidak boleh langsung mengatakan:

order pasti filled.

Karena harga bisa saja:

$$100 \rightarrow 98.9 \rightarrow 101$$

tanpa pernah tersedia cukup liquidity pada \$99.5\$.

Karena itu:

Signal data Ξ *Execution data*.

AA.8. Timestamp

Semua data harus mempunyai timestamp yang konsisten:

$$t_0, t_1, \dots, t_T.$$

Saya menyarankan menggunakan:

UTC

sebagai internal canonical timezone.

Jangan menyimpan dataset internal dengan:

WIB
EST
UTC

secara campur-aduk.

Semua dikonversi ke UTC.

AA.9. Tetapi UTC bukan berarti semua pasar memiliki informasi simultan

Ini jebakan yang sangat penting.

Misalnya:

$$t = 14 : 00 \text{ UTC}.$$

Data:

- crypto tersedia,
- DXY tersedia,

- Gold tersedia,
- saham AS mungkin baru saja membuka,
- data saham sebelumnya mungkin berasal dari sesi sebelumnya.

Maka kita tidak boleh hanya melakukan:

$$\text{merge}(\text{timestamp}).$$

Kita harus melakukan **information-time alignment**.

AA.10. Market clock

Untuk setiap asset i , kita definisikan:

$$T_i$$

sebagai himpunan timestamp ketika data asset tersebut tersedia.

Misalnya crypto:

$$T_{BTC} = \{\text{semua jam}\}.$$

Saham:

$$T_{AAPL} = \{\text{jam trading}\}.$$

AA.11. Last Observation Carried Forward

Untuk factor yang tidak update setiap jam, kita mungkin menggunakan:

$$f_t = f_{\tau^*}$$

dengan:

$$\tau^* = \max\{\tau \leq t : \tau \in T_f\}.$$

Namun **LOCF tidak boleh digunakan secara buta**.

Kita juga harus menyimpan:

$$Age_t = t - \tau^*.$$



Jadi model mengetahui:

$$f_t, \text{ Age}_t.$$

AA.12. Contoh DXY

Misalnya:

$$DXY_{10:00} = 100.5.$$

Kemudian tidak ada update sampai:

$$DXY_{11:00}.$$

Untuk crypto pada:

$$10 : 30,$$

kita boleh menggunakan:

$$DXY_{10:00}$$

jika memang data tersebut sudah tersedia.

Tetapi untuk:

$$09 : 30,$$

kita tidak boleh menggunakan:

$$DXY_{10:00}.$$

AA.13. Publication lag

Ini lebih penting lagi untuk data makro.

Misalnya suatu economic indicator mempunyai:

$$\text{Observation Date} = t$$

tetapi baru dipublikasikan:

$$t + \Delta_{pub}.$$

Model hanya boleh menggunakan setelah:

$t + \Delta_{pub}.$

Secara formal:

$$D_t^{available} = D_{\tau}^{observation} \quad \text{only if} \quad \tau + \Delta_{pub} \leq t.$$

AA.14. Ini menghasilkan konsep "as-of timestamp"

Setiap observasi sebaiknya mempunyai:

$observation_time$

dan:

$available_time.$

Misalnya:

Data	Observation	Available
Gold	10:00	10:01
DXY	10:00	10:01
CPI	08:00	08:30
AAPL close	16:00	16:00+

Model menggunakan:

$$available_time.$$

Bukan sekadar observation time.

AA.15. Data structure

Saya menyarankan setiap dataset memiliki kolom:

```
timestamp
available_at
symbol
open
high
low
close
volume
bid
ask
```

Untuk factor:

```
timestamp
available_at
factor
value
```

AA.16. Return target

Misalnya kita memprediksi return satu jam ke depan:

$$y_{i,t+1} = \ln \frac{P_{i,t+1}}{P_{i,t}}.$$

Untuk horizon H :

$$y_{i,t}^{(H)} = \ln \frac{P_{i,t+H}}{P_{i,t}}.$$

Jadi:

$$H = 1$$

berarti 1 jam.

AA.17. Jangan menggunakan target sebagai feature

Feature:

$$X_t$$

hanya menggunakan:

$$D_{\leq t}.$$

Target:

$$Y_t$$

menggunakan:

$$D_{t+H}.$$

Secara eksplisit:

$$\boxed{X_t = f(D_{\leq t})}$$

dan:

$$\boxed{Y_t = g(D_{t+H}).}$$

AA.18. Feature matrix

Untuk asset i :

$$X_{i,t} = \begin{bmatrix} r_{i,t} \\ r_{i,t-1} \\ \vdots \\ r_{i,t-L} \\ \sigma_{i,t} \\ Volume_{i,t} \\ Momentum_{i,t} \\ Factor_t \end{bmatrix}.$$

Kemudian:

$$X_t = [X_{1,t}, \dots, X_{N,t}].$$

AA.19. Rolling window

Misalnya:

$$L = 168.$$

Karena:

$$168 \text{ jam} = 7 \text{ hari}.$$

Maka covariance:

$$\hat{\Sigma}_t = \text{Cov}(r_{t-167:t}).$$

Expected return:

$$\hat{\mu}_t = \text{Model}(D_{t-167:t}).$$

AA.20. Jangan selalu memakai satu window

Nanti kita uji:

$$L \in \{48, 72, 168, 336, 720\}.$$

Yaitu kira-kira:

- 2 hari,
- 3 hari,
- 1 minggu,
- 2 minggu,
- 1 bulan.

Ini menjadi hyperparameter.

AA.21. Tetapi hyperparameter tidak boleh dipilih dari test set

Misalnya kita mencoba:

$$L = 48, 72, 168, 336.$$

Kita pilih:

$$L = 168$$

berdasarkan validation.

Kemudian:

$$L = 168$$

dikunci sebelum test.

Kalau kita melihat test lalu memilih yang terbaik:

test leakage.

AA.22. Walk-forward experiment

Sekarang kita masuk ke inti AA.

Misalkan data:

$$2021 - 01 - 01 \rightarrow 2025 - 12 - 31.$$

Kita buat:

$$Train \rightarrow Validation \rightarrow Test.$$

AA.23. Expanding window

Contoh:

Train: 2021 — 2022
Validation: 2023 Q1
Test: 2023 Q2

Train: 2021 — 2023 Q1
Validation: 2023 Q2
Test: 2023 Q3

Train: 2021 — 2023 Q2
Validation: 2023 Q3
Test: 2023 Q4

Training semakin besar.

AA.24. Rolling window

Alternatif:

Train: [————]
Validation: [—]
Test: [—]

Train: [————]
Validation: [—]
Test: [—]

Training window memiliki panjang tetap.

AA.25. Mana yang kita gunakan?

Untuk sistem kita saya menyarankan:

Forecast model

Rolling window.

Karena market berubah.

Factor beta

Rolling/Exponentially weighted.

Regime

Rolling.

Long-term baseline

Expanding window sebagai pembandingan.

Dengan demikian kita dapat membandingkan:

Adaptability vs Stability.

AA.26. Contoh satu fold

Misalkan:

$$T_{train} = 720h$$

$$T_{validation} = 168h$$

$$T_{test} = 168h.$$

Maka:

```
<----- 720h ----->
TRAIN
                        <---168h--->
                        VALIDATION
                                <---168h--->
                                TEST
```

Kemudian window bergeser.

AA.27. Decision timestamp

Pada:

t

kita menjalankan:

$$F_t \rightarrow Model_t \rightarrow Optimization_t \rightarrow Order_t.$$

Order baru boleh dianggap aktif:

$$t_{submit} \geq t.$$

AA.28. Order expiration

Order limit tidak boleh hidup selamanya.

Kita definisikan:

$$T_{expire}.$$

Jika:

$$t > T_{expire}$$

dan order belum filled:

$$\boxed{Cancel.}$$

Misalnya:

$$T_{expire} = 3h.$$

AA.29. Mengapa ini cocok dengan desain kita sebelumnya?

Karena Tahap Z mengatakan:

"setiap jam evaluasi apakah order masih layak."

Maka:

$$t_0 \rightarrow Order$$

Jika belum filled:

$t_1 \rightarrow Re - evaluate.$

Jika:

$$EV_{new} < 0,$$

cancel.

AA.30. State machine

Order:

$Pending \rightarrow Filled$

atau:

$Pending \rightarrow Cancelled.$

Position:

$Filled \rightarrow Open.$

Kemudian:

$Open \rightarrow BEP \rightarrow Trailing \rightarrow Closed.$

AA.31. Data universe untuk crypto

Untuk eksperimen pertama, saya menyarankan:

Core factors

BTC, ETH

Macro

$DXY, Gold$

Risk sentiment

VIX

Equity market

SPX

Jadi:

$$F_t = [r_{BTC}, r_{ETH}, r_{DXY}, r_{Gold}, r_{VIX}, r_{SPX}].$$

AA.32. Target crypto

Jangan langsung mengambil semua altcoin.

Pilih misalnya:

$SOL, XRP, ADA, AVAX, LINK, DOGE$

sebagai contoh universe eksperimen.

BTC dan ETH menjadi factors, bukan target.

AA.33. Kenapa BTC dan ETH tidak sekaligus menjadi target?

Untuk eksperimen awal:

BTC, ETH

digunakan sebagai market leadership.

Kita ingin mengetahui:

Apakah altcoin movement dapat dijelaskan oleh BTC/ETH + macro factors?

Baru nanti kita dapat mengizinkan BTC/ETH menjadi selectable assets.

AA.34. Universe saham

Untuk eksperimen kedua:

$AAPL, MSFT, NVDA, AMZN, META, GOOGL$

dan factors:

$SPX, NDX, DXY, Gold, VIX, US10Y.$

Kita ingin melihat apakah:

individual stock

dapat dimodelkan melalui:

market + macro + sector + idiosyncratic signal.

AA.35. Sector factor

Untuk saham, kita bahkan bisa menambahkan:

$XLK, XLF, XLE, XLV, \dots$

sebagai sector factors.

Sehingga:

$$F_t = [SPX, NDX, DXY, Gold, VIX, US10Y, XLK, XLF, \dots].$$

Ini akan membuat factor model jauh lebih ekonomis.

AA.36. Cross-market lag

Ini bagian yang menarik.

Kita tidak hanya menggunakan:

$$F_t.$$

Kita gunakan:

$$F_t, F_{t-1}, F_{t-2}, \dots$$

Misalnya:

$$X_t^{factor} = [r_{BTC,t}, r_{BTC,t-1}, r_{BTC,t-2}, r_{ETH,t}, \dots].$$

Karena pengaruh factor mungkin tidak instantaneous.

AA.37. Distributed lag model

Misalnya:

$$r_{i,t+1} = \alpha_i + \sum_{k=0}^K \beta_{i,k} F_{t-k} + \epsilon_{i,t+1}.$$

Ini sangat menarik secara finansial.

Karena kita dapat mengetahui apakah:

$$BTC_t$$

mempengaruhi altcoin:

$$t+1, t+2, \dots$$

bukan hanya correlation contemporaneous.

AA.38. Ini bisa menjadi sumber signal

Misalnya hasil estimasi:

$$\beta_{SOL,BTC,1} > 0.$$

Artinya secara statistik:

$$BTC_t$$

mempunyai hubungan dengan:

$$SOL_{t+1}.$$

Tetapi kita harus hati-hati membedakan:

correlation

dengan:

causality.

Kita tidak perlu menyebutnya causal tanpa pengujian yang tepat.

AA.39. Factor momentum

Kita juga dapat mendefinisikan:

$$M_{BTC,t}^{(H)} = \sum_{k=0}^{H-1} r_{BTC,t-k}.$$

Demikian:

$$M_{ETH,t}^{(H)}.$$

Untuk DXY:

$$M_{DXY,t}^{(H)}.$$

Gold:

$$M_{Gold,t}^{(H)}.$$

AA.40. Relative factor flow

Kita bisa membangun:

$$Flow_t = w_1 r_{BTC,t} + w_2 r_{ETH,t} - w_3 r_{DXY,t} + w_4 r_{Gold,t}.$$

Namun saya tidak ingin kita menentukan w_i secara manual.

Kita biarkan:

$$w^* = \arg \min_w \text{Loss}(w)$$

di training set.

AA.41. Bahkan kita dapat menggunakan PCA

Misalkan:

$$F_t \in \mathbb{R}^K.$$

Covariance:

$$\Sigma_F.$$

Eigenproblem:

$$\Sigma_F v_j = \lambda_j v_j.$$

Kemudian:

$$P C_j = v_j^\top F_t.$$

Ini dapat mengurangi dimensionality.

AA.42. Namun untuk versi pertama jangan gunakan PCA sebagai default

Kenapa?

Karena interpretasi:

$$BTC \rightarrow SOL$$

lebih jelas daripada:

$$P C_1 \rightarrow SOL.$$

Kita ingin menjaga interpretability terlebih dahulu.

AA.43. Feature groups

Saya ingin setiap feature diberi label:

PRICE
VOLUME
VOLATILITY
FACTOR
MOMENTUM
REGIME
ORDERFLOW

Dengan demikian nanti kita dapat melakukan:

Ablation Study.

AA.44. Ablation study

Misalnya:

Model A

Price

Model B

Price + Factor

Model C

Price + Factor + Regime

Model D

Price + Factor + Regime + OrderFlow

Kemudian lihat:

$$\Delta Sharpe.$$

Ini sangat penting untuk mengetahui apakah kompleksitas benar-benar memberikan nilai.

AA.45. Dataset final

Secara konseptual satu baris:

$$Row_t = [X_t, F_t, Regime_t, Position_t, Y_{t+1}].$$

Tetapi ketika training:

$$Position_t$$

harus berasal dari state sebelumnya.

Dan:

$$Y_{t+1}$$

tidak boleh tersedia sebagai input.

AA.46. Train/validation/test harus benar-benar temporal

Bukan:

```
train_test_split(..., shuffle=True)
```

karena itu menghancurkan struktur waktu.

Kita harus:

$$t_{train} < t_{validation} < t_{test}.$$

AA.47. Purging

Karena target kita menggunakan horizon:

$$H.$$

Misalnya:

$$Y_t = P_{t+1}/P_t.$$

Observasi di dekat boundary dapat overlap.

Maka kita perlu:

$$\boxed{\text{purge period} \geq H.}$$

Misalnya:

TRAIN | purge | VALIDATION

untuk menghindari overlapping labels.

AA.48. Embargo

Selain purge, kita bisa menggunakan:

$$\boxed{\text{embargo.}}$$

Artinya setelah validation/test boundary, kita memberikan gap tertentu sebelum data berikutnya digunakan.

Ini berguna terutama jika label overlap dan data sangat autocorrelated.

AA.49. Data leakage checklist

Sebelum model dianggap valid:

Leakage 1

Scaler menggunakan seluruh data.



Leakage 2

Covariance dihitung dari masa depan.



Leakage 3

Hyperparameter dipilih berdasarkan test.



Leakage 4

Order fill menggunakan future low/high tanpa execution model.



Leakage 5

Survivorship bias.



Leakage 6

Delisted stock dihilangkan.



Leakage 7

Corporate action tidak disesuaikan.



Leakage 8

Macro data menggunakan revision terakhir.



AA.50. Revision bias

Untuk data ekonomi, ada masalah:

$$Data_{initial} \neq Data_{revised}.$$

Jika kita menggunakan dataset hari ini:

$$GDP_{2021}$$

yang telah mengalami revisi berkali-kali, kita mungkin memberikan model informasi yang pada 2021 belum diketahui.

Idealnya:

point-in-time data.

AA.51. Survivorship bias

Misalkan tahun 2021 kita memilih hanya saham yang masih ada pada 2026.

Maka:

$$Universe_{2021}$$

sudah mengandung informasi masa depan.

Salah.

Universe harus dibentuk berdasarkan:

$$available\ universe_t.$$

AA.52. Delisting

Jika asset delisting:

$$P_t \rightarrow 0$$

atau memiliki liquidation event, data tersebut tidak boleh sekadar dihapus.

Karena:

removing losers

akan membuat performance terlihat terlalu bagus.

AA.53. Crypto memiliki masalah berbeda

Crypto tidak terlalu terkena:

market close.

Tetapi memiliki:

- listing/delisting,
- exchange-specific liquidity,
- perpetual funding,
- different trading pairs,
- symbol changes.

Jadi universe juga harus memiliki:

listing_t

dan:

delisting_t.

AA.54. Exchange-specific data

Ini sangat penting untuk sistem live nanti.

Harga:

$$P_{BTC}^{Binance} \neq P_{BTC}^{Coinbase}$$

secara tepat pada setiap waktu.

Maka jangan menggabungkan:

price dari exchange A
order book exchange B
volume exchange C

tanpa model yang jelas.

AA.55. Untuk backtest awal

Saya menyarankan:

one venue.

Misalnya satu exchange untuk crypto.

Kemudian:

$P_t, Volume_t, OrderBook_t$

berasal dari venue yang sama.

AA.56. Untuk saham

Gunakan satu sumber consolidated market data untuk baseline.

Kemudian baru nanti kita tambahkan:

market microstructure.

AA.57. Data frequency

Untuk decision:

$1h.$

Untuk execution:

$1m.$

Untuk order book:

tick/depth

jika tersedia.

Jadi hierarchy:

Tick → 1m → 1h → Daily.

AA.58. Aggregation

Misalnya data 1m:

$$\{P_{t,1}, P_{t,2}, ..., P_{t,60}\}$$

menjadi:

$$O_t = P_{t,1}$$

$$H_t = \max_j P_{t,j}$$

$$L_t = \min_j P_{t,j}$$

$$C_t = P_{t,60}.$$

Volume:

$$V_t = \sum_j V_{t,j}.$$

AA.59. Order book features

Jika tersedia:

Bid:

$$B_t$$

Ask:

$$A_t.$$

Spread:

$$S_t = A_t - B_t.$$

Mid-price:

$$M_t = \frac{A_t + B_t}{2}.$$

AA.60. Order book imbalance

Dengan depth K :

$$I_t = \frac{\sum_{k=1}^K Q_{B,k} - \sum_{k=1}^K Q_{A,k}}{\sum_{k=1}^K Q_{B,k} + \sum_{k=1}^K Q_{A,k}}.$$

Sehingga:

$$-1 \leq I_t \leq 1.$$

Ini dapat menjadi feature:

$$X_t^{OB}.$$

AA.61. Tetapi jangan memasukkan order book ke model 1h secara mentah

Order book sangat noisy.

Lebih baik agregasikan:

$$I_t^{1h} = \text{Mean}(I_{t,\tau})$$

atau:

$$\text{Median}(I_{t,\tau}).$$

Bisa juga menggunakan:

$$\text{quantile}.$$

AA.62. Liquidity feature

Misalnya:

$$ADV_t = \frac{1}{L} \sum_{\tau=t-L}^t DollarVolume_{\tau}.$$

Kemudian:

$$LiquidityScore_i = f(ADV_i, Spread_i, Depth_i).$$

AA.63. Optimizer harus melihat liquidity

Kita dapat menambahkan:

$$x_i = 0$$

jika:

$$LiquidityScore_i < L_{min}.$$

Atau penalty:

$$P_L \sum_i (1 - L_i) x_i.$$

AA.64. Slippage model

Versi pertama:

$$Slippage_i = \alpha \frac{Spread_i}{2} + \beta \frac{OrderSize_i}{Depth_i}.$$

Kemudian:

$$Cost_i = Fee_i + Slippage_i.$$

Nanti kita dapat mengganti dengan model empiris.

AA.65. Ini masuk ke QUBO

Jika asset i memiliki expected net return:

$$\mu_i^{net} = \mu_i - Cost_i.$$

Maka QUBO menggunakan:

$$\boxed{-\mu_i^{net} x_i.}$$

Jadi optimizer tidak mengoptimalkan:

Gross Return

tetapi:

$$\boxed{Net Expected Return.}$$

AA.66. Bahkan covariance dapat disesuaikan

Jika execution uncertainty besar:

$$\Sigma_{effective} = \Sigma_{market} + \Sigma_{execution}.$$

Kemudian:

$$H(x) = -\mu^T x + \lambda x^T \Sigma_{effective} x.$$

Ini lebih konservatif.

AA.67. Struktur satu decision cycle

Sekarang semuanya bisa kita satukan.

Pada:

$t.$

Step 1

Ambil:

$$D_{\leq t}.$$

Step 2

Bangun:

$$X_t.$$

Step 3

Update factor:

$$F_t.$$

Step 4

Estimate regime:

$$z_t.$$

Step 5

Estimate:

$$\hat{\mu}_t, \hat{\Sigma}_t.$$

Step 6

Build:

$$H_t(x).$$

Step 7

Solve:

$$x_t^*.$$

Step 8

Allocation:

$$w_t^*.$$

Step 9

Risk sizing:

$$q_t^*.$$

Step 10

Generate:

$$O_t.$$

Step 11

Execute.

Step 12

Update:

$$State_{t+1}.$$

AA.68. Formal recursive system

Kita bisa menuliskannya:

$$S_{t+1} = T(S_t, D_t, a_t)$$

dengan action:

$$a_t = \pi(F_t).$$

Policy kita sebenarnya adalah:

$$\pi = \pi_{\text{execution}} \circ \pi_{\text{risk}} \circ \pi_{\text{allocation}} \circ \pi_{\text{optimization}} \circ \pi_{\text{forecast}}.$$

Ini mulai terlihat seperti **closed-loop stochastic control system**.

AA.69. Dan di sinilah desain kita menjadi menarik

Sistem kita bukan:

$$Prediction \rightarrow Buy.$$

Tetapi:

$$Prediction \rightarrow Optimization \rightarrow Risk \rightarrow Execution \rightarrow State \rightarrow Prediction.$$

Jadi keputusan hari ini mengubah:

$$S_{t+1},$$

yang kemudian mempengaruhi keputusan berikutnya.

AA.70. Eksperimen pertama yang saya rekomendasikan

Kita jangan langsung membuat model besar.

Saya ingin **Experiment AA-1** menjadi sangat sederhana tetapi scientifically clean.

Universe

$$SOL, XRP, ADA, AVAX, LINK, DOGE$$

Factors

$$BTC, ETH, DXY, Gold, SPX, VIX$$

Timeframe

$$1h$$

Forecast horizon

$$H = 1h$$

Rolling window

$$L = 168h$$

Regime

3-state.

Optimizer

Exact QUBO.

Execution

1m historical simulation.

Risk

Fixed:

$$R_{trade} = \$1.$$

AA.71. Mengapa mulai dari Exact QUBO?

Karena kita ingin memisahkan dua pertanyaan.

Pertanyaan pertama:

Apakah mathematical trading problem kita sendiri menghasilkan keputusan yang bagus?

Kita jawab menggunakan:

Exact Solver.

Pertanyaan kedua:

Apakah VQE/QAOA mampu menyelesaikan problem tersebut?

Baru kemudian:

$$Exact \leftrightarrow VQE \leftrightarrow QAOA.$$

Ini sangat penting untuk penelitian quantum.

AA.72. Experiment AA-2

Setelah AA-1:

Exact

kita lakukan:

Classical QUBO.

Misalnya:

Simulated Annealing

atau solver classical lainnya.

AA.73. Experiment AA-3

Kemudian:

VQE.

Ukur:

Gap_{VQE}

terhadap:

E^ .*

AA.74. Experiment AA-4

Kemudian:

QAOA.

Ukur:

$$Gap_{QAOA}.$$

AA.75. Experiment AA-5

Baru kita masukkan:

$$Execution\ cost.$$

Bandingkan:

$$Gross$$

vs:

$$Net.$$

AA.76. Experiment AA-6

Kemudian:

$$Crypto$$

vs:

$$Equity.$$

Framework yang sama:

different market data.

AA.77. Experiment AA-7

Kemudian stress test:

$$Bull$$

Bear

High Volatility

Low Liquidity

Market Crash.

Kita ingin melihat:

Performance(z).

AA.78. Experiment AA-8

Terakhir:

Ablation.

Bandingkan:

Price

VS:

Price + Factor

VS:

Price + Factor + Regime

VS:

Price + Factor + Regime + OrderBook.

AA.79. Output yang harus kita simpan

Setiap decision timestamp harus menghasilkan log:

```
timestamp
regime
mu
covariance
qubo_matrix
ising_h
ising_J
solver
solution
objective
feasibility
weights
quantity
entry
stop_loss
take_profit
expected_return
expected_risk
spread
slippage
fill_status
realized_pnl
```

Ini penting.

Karena nanti kita bisa menjawab:

"Mengapa trade pada 2026-05-13 pukul 10:00 dilakukan?"

Secara matematis.

AA.80. Kita bahkan bisa merekonstruksi setiap keputusan

Misalnya:

$$t = 10 : 00.$$

Model melihat:

$$BTC = -0.8\sigma$$

$$ETH = -0.5\sigma$$

$$DXY = +0.7\sigma$$

$$Gold = +0.2\sigma$$

dan:

$$Regime = Stress.$$

Kemudian:

$$\mu_{SOL} = -0.1\%$$

$$\mu_{XRP} = +0.4\%.$$

Optimizer kemudian memilih:

$$x^* = [0, 1, 0, 1, 0, 0].$$

Kita dapat mengetahui **seluruh rantai sebab-akibat komputasionalnya**.

AA.81. Dan inilah yang nantinya sangat berguna untuk skripsi/riset

Kita bisa menunjukkan:

Market Information → Mathematical Formulation → Quantum Optimization → Trading Decision.

Bukan hanya:

"VQE menghasilkan portfolio."

AA.82. Spesifikasi AA final

Jadi untuk saat ini saya ingin kita **mengunci** konfigurasi baseline:

Decision	1h
Execution	1m
Crypto Targets	<i>SOL, XRP, ADA, AVAX, LINK, DOGE</i>
Crypto Factors	<i>BTC, ETH</i>
Macro Factors	<i>DXY, Gold, SPX, VIX</i>
Forecast Horizon	1h
Rolling Window	168h
Regime States	3
Risk/trade	\$1
Optimization	<i>QUBO</i>
Initial Solver	<i>Exact</i>
Validation	<i>Walk – forward</i>
Execution	<i>realistic</i>
Timezone	<i>UTC</i>

Ini **bukan berarti angka-angka tersebut final selamanya**. Mereka adalah baseline yang kita gunakan agar eksperimen pertama memiliki definisi yang jelas.

AA.83. Hal yang paling penting dari Tahap AA

Ada satu perubahan konseptual yang ingin saya tekankan.

Sebelumnya kita berpikir:

Data → Model.

Sekarang kita harus berpikir:

Data → Information Set → Model → Decision → Execution → Observed Outcome.

Dengan kata lain, **timestamp adalah bagian dari matematika model**, bukan sekadar metadata dataset.

Dan untuk sistem quantitative trading yang ingin kita bangun, itu mungkin sama pentingnya dengan QUBO, VQE, atau QAOA itu sendiri.

Tahap berikutnya: AB

Setelah AA, saya menyarankan kita masuk ke:

Tahap AB — Mathematical Feature & Factor Engine

Di sana kita mulai benar-benar **menurunkan setiap feature dari data mentah**, bukan sekadar menyebut nama indikator.

Kita akan membangun secara matematis:



lalu menurunkan **factor model untuk crypto dan saham secara terpadu**, termasuk:

$$r_{i,t+1} = \alpha_i + B_i F_t + \sum_{k=1}^K B_{i,k} F_{t-k} + \epsilon_{i,t+1},$$

estimasi β rolling, covariance factor model, shrinkage, cross-asset lag, dan akhirnya bagaimana semua itu masuk ke:

$$\hat{\mu}_t, \hat{\Sigma}_t$$

yang kemudian menjadi input langsung ke **QUBO/Ising** kita.