

Prompt:

8/17/2026, 10:15:55 PM

lanjut Tahap AB

Response:

8/17/2026, 10:15:56 PM

Remembering

Recalled trading architecture, decisions, risk rules, and Stage AB focus

Worked for 6s

Tahap AB — Mathematical Feature & Factor Engine

Baik. Pada **Tahap AA** kita sudah mengunci arsitektur data:

Raw Market Data $\rightarrow F_t \rightarrow$ Feature/Factor Engine $\rightarrow (\hat{\mu}_t, \hat{\Sigma}_t) \rightarrow$ QUBO/Ising $\rightarrow$ Trading Decision

Maka Tahap AB adalah tempat kita membangun bagian yang selama ini masih berupa kotak hitam:

Raw data $\rightarrow \hat{\mu}_t, \hat{\Sigma}_t$

Dan saya ingin kita membuatnya **secara matematis**, bukan sekadar memasukkan indikator teknikal seperti RSI, MACD, dan sebagainya.

AB.1. Tujuan Mathematical Feature Engine

Pada setiap waktu keputusan t , sistem memiliki informasi:

$F_t.$

Dari informasi tersebut kita ingin membentuk feature vector:

$\mathbf{x}_{i,t} = f_i(F_t)$

untuk setiap asset i .

Kemudian model forecast menghasilkan:

$$\hat{\mu}_{i,t} = E[r_{i,t+1} | F_t]$$

dan covariance:

$$\hat{\Sigma}_t = Cov(\mathbf{r}_{t+1} | F_t).$$

Jadi sebenarnya ada **dua mesin berbeda**:

$$\text{Feature Engine} \rightarrow \text{Return Forecast}$$

dan:

$$\text{Feature/Factor Engine} \rightarrow \text{Risk Forecast.}$$

Keduanya akhirnya bertemu di optimizer.

AB.2. Return sebagai variabel fundamental

Kita mulai dari harga:

$$P_{i,t}.$$

Saya ingin menggunakan log-return:

$$r_{i,t} = \ln \frac{P_{i,t}}{P_{i,t-1}}$$

karena memiliki sifat:

$$r_{i,t}^{(H)} = \ln \frac{P_{i,t}}{P_{i,t-H}} = \sum_{k=0}^{H-1} r_{i,t-k}.$$

Ini sangat berguna untuk multi-horizon model.

AB.3. Return vector

Untuk N asset:

$$\mathbf{r}_t = \begin{bmatrix} r_{1,t} \\ r_{2,t} \\ \vdots \\ r_{N,t} \end{bmatrix}.$$

Untuk baseline kita:

$$N = 6$$

dengan:

$$A_T = \{SOL, XRP, ADA, AVAX, LINK, DOGE\}.$$

Maka:

$$\mathbf{r}_t \in \mathbb{R}^6.$$

AB.4. Multi-horizon return

Satu return saja terlalu miskin.

Kita definisikan:

$$R_{i,t}^{(H)} = \sum_{k=0}^{H-1} r_{i,t-k}.$$

Kita dapat mengambil:

$$H \in \{1, 3, 6, 12, 24, 72, 168\}.$$

Karena decision timeframe kita adalah 1 jam, maka:

- $H = 1$: 1 jam,
- $H = 3$: 3 jam,
- $H = 6$: 6 jam,
- $H = 12$: 12 jam,

- $H = 24$: 1 hari,
- $H = 72$: 3 hari,
- $H = 168$: 1 minggu.

AB.5. Momentum

Momentum sederhana:

$$M_{i,t}^{(H)} = \sum_{k=0}^{H-1} r_{i,t-k}.$$

Secara matematis sebenarnya sama dengan cumulative log-return.

Tetapi nanti kita dapat menggunakan beberapa transformasi:

$$M_{i,t}^{(H)} = \ln \frac{P_{i,t}}{P_{i,t-H}}.$$

AB.6. Normalized momentum

Momentum absolut tidak dapat dibandingkan dengan baik antar-asset.

Maka kita normalisasi dengan volatility:

$$Z_{i,t}^{(H)} = \frac{M_{i,t}^{(H)}}{\hat{\sigma}_{i,t}^{(H)} + \epsilon}.$$

Dengan:

$$\epsilon > 0$$

untuk mencegah pembagian nol.

Sekarang Z dapat dibandingkan antar asset.

AB.7. Volatility

Volatility rolling:

$$\sigma_{i,t}^{(L)} = \sqrt{\frac{1}{L-1} \sum_{k=0}^{L-1} (r_{i,t-k} - \bar{r}_{i,t})^2}.$$

Baseline kita:

$$L = 168.$$

Jadi sistem mengetahui volatility satu minggu terakhir.

AB.8. EWMA volatility

Volatility rolling memiliki kelemahan: semua observasi mendapat bobot sama.

Kita dapat menggunakan EWMA:

$$\sigma_{i,t}^2 = \lambda \sigma_{i,t-1}^2 + (1 - \lambda) r_{i,t-1}^2.$$

Dengan:

$$0 < \lambda < 1.$$

Semakin besar λ , semakin lambat model bereaksi terhadap perubahan volatility.

AB.9. Mengapa volatility penting?

Karena:

$$\mu_i = 1\%$$

tidak berarti sama jika:

$$\sigma_i = 0.5\%$$

dibanding:

$$\sigma_i = 5\%.$$

Maka signal harus dipandang sebagai:

return relative to uncertainty.

AB.10. Z-score return

Kita dapat membuat:

$$Z_{i,t} = \frac{r_{i,t} - \bar{r}_{i,t}^{(L)}}{\sigma_{i,t}^{(L)} + \epsilon}.$$

Ini memberi informasi apakah return saat ini abnormal relatif terhadap regime lokal.

AB.11. Volume

Volume mentah juga tidak comparable.

Gunakan:

$$V Z_{i,t} = \frac{V_{i,t} - \bar{V}_{i,t}^{(L)}}{\sigma_{V_{i,t}}^{(L)} + \epsilon}.$$

Ini memberi:

Apakah pergerakan harga sekarang terjadi dengan volume abnormal?

AB.12. Dollar volume

Untuk likuiditas:

$$DV_{i,t} = P_{i,t} V_{i,t}.$$

Kemudian:

$$ADV_{i,t}^{(L)} = \frac{1}{L} \sum_{k=0}^{L-1} DV_{i,t-k}.$$

Ini akan digunakan juga pada execution/risk engine.

AB.13. High-low range

Kita dapat mendefinisikan:

$$\boxed{Range_{i,t} = \frac{H_{i,t} - L_{i,t}}{C_{i,t}}}.$$

Kemudian rolling average:

$$\overline{Range}_{i,t}^{(L)} = \frac{1}{L} \sum_{k=0}^{L-1} Range_{i,t-k}.$$

Ini merupakan proxy volatility intrabar.

AB.14. Sekarang masuk ke bagian yang jauh lebih penting: cross-asset factors

Misalkan target kita adalah SOL.

Kita tidak hanya melihat:

$$r_{SOL,t}.$$

Kita melihat:

$$\mathbf{f}_t = \begin{bmatrix} r_{BTC,t} \\ r_{ETH,t} \\ r_{DXY,t} \\ r_{Gold,t} \\ r_{SPX,t} \\ r_{VIX,t} \end{bmatrix}.$$

Dengan:

$$K = 6.$$

AB.15. Factor model

Model dasar:

$$\mathbf{r}_t = \boldsymbol{\alpha} + B\mathbf{f}_t + \boldsymbol{\epsilon}_t$$

dengan:

$$B \in \mathbb{R}^{N \times K}.$$

Elemen:

$$\beta_{ik}$$

mengukur sensitivitas asset i terhadap factor k .

AB.16. Contoh interpretasi

Misalkan:

$$\beta_{SOL,BTC} = 1.4.$$

Secara sederhana:

$$\Delta SOL \approx 1.4 \Delta BTC$$

untuk komponen pergerakan yang dijelaskan oleh factor tersebut.

Sedangkan:

$$\beta_{SOL,DXY} = -0.3.$$

Maka kenaikan DXY secara statistik berkaitan dengan tekanan terhadap SOL.

Ini bukan klaim kausalitas.

Kita hanya mengatakan:

conditional exposure.

AB.17. Estimasi beta

Untuk setiap asset:

$$\mathbf{r}_i = X\boldsymbol{\beta}_i + \epsilon_i.$$

OLS:

$$\hat{\boldsymbol{\beta}}_i = (X^\top X)^{-1} X^\top \mathbf{r}_i.$$

Namun kita tidak akan menghitungnya menggunakan seluruh history.

AB.18. Rolling beta

Pada waktu t :

$$\hat{B}_t = \arg \min_B \sum_{\tau=t-L+1}^t \|\mathbf{r}_\tau - \boldsymbol{\alpha} - B\mathbf{f}_\tau\|^2.$$

Jadi beta berubah:

$$B_t \neq B_{t-1}.$$

Ini jauh lebih masuk akal untuk short-term trading.

AB.19. Mengapa beta harus berubah?

Karena hubungan pasar dapat berubah.

Misalnya:

Regime 1

$$\beta_{SOL,BTC} = 1.2.$$

Regime 2

$$\beta_{SOL,BTC} = 2.0.$$

Jika kita menggunakan beta jangka panjang:

$$\beta = 1.2$$

maka model mungkin underestimate risiko SOL ketika BTC menjadi dominant driver.

AB.20. Weighted regression

Kita dapat memberikan bobot lebih besar pada data terbaru:

$$\min_B \sum_{\tau=t-L+1}^t w_{t-\tau} \|\mathbf{r}_\tau - B\mathbf{f}_\tau\|^2.$$

Misalnya:

$$w_k = \lambda^k.$$

Ini menghasilkan **exponentially weighted factor model**.

AB.21. Residual return

Setelah factor exposure diketahui:

$$\hat{\epsilon}_{i,t} = r_{i,t} - \hat{\alpha}_i - \hat{\beta}_i^\top \mathbf{f}_t.$$

Ini sangat penting.

Karena kita sekarang dapat memisahkan:

$$Total\ Return = Factor\ Return + Idiosyncratic\ Return.$$

AB.22. Residual momentum

Kita bahkan dapat menghitung momentum residual:

$$RM_{i,t}^{(H)} = \sum_{k=0}^{H-1} \hat{\epsilon}_{i,t-k}.$$



Ini jauh lebih menarik daripada momentum harga biasa.

Misalnya:

SOL

naik karena:

BTC

naik.

Itu belum tentu merupakan alpha.

Tetapi jika:

SOL

mengungguli apa yang dijelaskan oleh BTC/ETH/macro factors:

$$\epsilon_{SOL} > 0,$$

maka terdapat **relative strength** yang lebih spesifik terhadap SOL.

AB.23. Ini menghasilkan dua jenis momentum

Market momentum

$$M_{i,t}^{market}$$

dan:

Residual momentum

$$M_{i,t}^{residual}.$$

Kemudian feature vector dapat memiliki:

$$x_{i,t} = [M^{market}, M^{residual}, \sigma, VZ, \dots].$$

AB.24. Cross-asset lag

Sekarang kita masuk ke ide yang sebelumnya sudah kita tetapkan.

Model:

$$r_{i,t+1} = \alpha_i + \sum_{k=0}^K B_{i,k} f_{t-k} + \epsilon_{i,t+1}.$$

Misalnya:

$$r_{SOL,t+1} = \alpha + \beta_0 r_{BTC,t} + \beta_1 r_{BTC,t-1} + \beta_2 r_{BTC,t-2} + \epsilon.$$

AB.25. Mengapa ini penting?

Bayangkan:

BTC

bergerak lebih dahulu.

Kemudian:

SOL

bereaksi beberapa jam kemudian.

Jika pola tersebut stabil, maka:

BTC_t

bisa menjadi **leading factor**.

Model kita tidak lagi sekadar bertanya:

"Apa hubungan BTC dan SOL?"

tetapi:

"Apakah informasi BTC sekarang mengandung informasi tentang return SOL berikutnya?"

AB.26. Distributed-lag factor matrix

Kita dapat mendefinisikan:

$$\mathbf{F}_t^{lag} = \begin{bmatrix} \mathbf{f}_t \\ \mathbf{f}_{t-1} \\ \vdots \\ \mathbf{f}_{t-K} \end{bmatrix}.$$

Kemudian:

$$r_{i,t+1} = \alpha_i + \Theta_i^\top \mathbf{F}_t^{lag} + \epsilon_{i,t+1}.$$

AB.27. Jangan membuat K terlalu besar

Jika:

$$K = 24$$

dan factor:

$$6,$$

maka:

$$6 \times 25 = 150$$

coefficient per asset.

Dengan hanya:

$$168$$

observasi, kita mengalami masalah:

$$p \approx n.$$

Maka estimasi menjadi tidak stabil.

AB.28. Regularisasi ridge

Kita dapat menggunakan:

$$\hat{\theta} = \arg \min_{\theta} [\|y - X\theta\|^2 + \lambda \|\theta\|_2^2].$$

Solusinya:

$$\hat{\theta} = (X^T X + \lambda I)^{-1} X^T y.$$

Ini sangat cocok untuk factor model kita.

AB.29. Mengapa ridge lebih cocok daripada langsung memperbanyak feature?

Karena kita ingin:

predictive stability

bukan:

training fit.

Dalam trading:

$$R_{train}^2$$

yang tinggi tidak berarti:

$$P \& L_{live}$$

tinggi.

AB.30. Factor interaction

Kita bahkan dapat memiliki:

$$BTC \times DXY.$$

Misalnya:

$$x_t = r_{BTC,t} r_{DXY,t}.$$

Kemudian:

$$r_{SOL,t+1} = \alpha + \beta_1 BTC_t + \beta_2 DXY_t + \beta_3 (BTC_t DXY_t) + \epsilon.$$

Ini memungkinkan hubungan non-additive.

AB.31. Tetapi jangan terlalu cepat memasukkan interaction

Karena jumlah parameter bertambah.

Kita gunakan prinsip:

<i>complexity</i> harus dibayar dengan evidence.
--

Setiap feature tambahan harus melewati:

$$walk - forward$$

dan:

$$ablation.$$

AB.32. Factor covariance

Sekarang bagian kedua yang sangat penting:

$$\hat{\Sigma}_t.$$

Dari:

$$r_t = B_t f_t + \epsilon_t,$$

kita mendapatkan:

$$\Sigma_t = B_t \Sigma_{F,t} B_t^\top + \Sigma_{\epsilon,t}.$$

Ini adalah **factor covariance model**.

AB.33. Mengapa tidak langsung menghitung covariance asset?

Kita bisa:

$$\hat{\Sigma}_{sample} = Cov(r).$$

Tetapi jika:

$$N$$

besar dan:

$$L$$

relatif kecil, covariance sample menjadi noisy.

Factor model memberikan struktur:

$$\text{common risk} + \text{idiosyncratic risk}.$$

AB.34. Factor covariance

Definisikan:

$$\Sigma_{F,t} = Cov(f_t).$$

Rolling estimate:

$$\hat{\Sigma}_{F,t} = Cov(f_{t-L+1:t}).$$

Bisa juga EWMA.

AB.35. Residual covariance

Residual:

$$\epsilon_t = r_t - B_t f_t.$$

Jika kita mengasumsikan residual relatif independent antar asset:

$$\Sigma_{\epsilon,t} \approx \text{diag}(\sigma_{\epsilon,1}^2, \dots, \sigma_{\epsilon,N}^2).$$

Ini adalah **diagonal factor model**.

AB.36. Mengapa asumsi diagonal menarik?

Karena:

$$N(N-1)/2$$

off-diagonal covariance harus diestimasi jika menggunakan covariance penuh.

Untuk:

$$N = 100,$$

itu:

$$4950$$

parameter.

Factor model dapat mengurangi kompleksitas secara drastis.

AB.37. Tetapi residual sebenarnya bisa berkorelasi

Misalnya:

$$\epsilon_{SOL}$$

dan:

$$\epsilon_{AVAX}$$

masih berkorelasi.

Maka nanti kita dapat menggunakan:

$$\Sigma_{\epsilon} = D + R.$$

Tetapi baseline kita gunakan:

$$\Sigma_{\epsilon} = D.$$

AB.38. Shrinkage covariance

Kita juga dapat melakukan shrinkage:

$$\hat{\Sigma} = (1 - \rho)\hat{\Sigma}_{sample} + \rho T.$$

dengan T target covariance.

Contoh:

$$T = \text{diag}(\hat{\Sigma}_{sample}).$$

Ini mengurangi estimation error.

AB.39. EWMA covariance

Alternatif:

$$\Sigma_t = \lambda \Sigma_{t-1} + (1 - \lambda) r_{t-1} r_{t-1}^T.$$

Secara online:

$$\Sigma_t$$

selalu diperbarui tanpa menghitung ulang seluruh history.

AB.40. Kita sebenarnya akan menggunakan kombinasi

Untuk baseline:

$$\Sigma_t = B_t \Sigma_{F,t} B_t^\top + D_{\epsilon,t}.$$

Kemudian:

$$\Sigma_{F,t}$$

dapat menggunakan EWMA.

Dan:

$$D_{\epsilon,t}$$

juga dapat menggunakan EWMA residual volatility.

AB.41. Sekarang expected return

Ini bagian yang akan menentukan:

$$\hat{\mu}_t.$$

Model paling sederhana:

$$\hat{\mu}_t = \alpha_t + \hat{B}_t \hat{f}_{t+1}.$$

Masalahnya:

kita tidak mengetahui $\hat{f}_{t+1}$.

Maka kita perlu memprediksi factor.

AB.42. Factor forecast

Misalnya:

$$\hat{f}_{t+1} = E[f_{t+1} | F_t].$$

Kita dapat menggunakan model sederhana:

$$\hat{f}_{t+1} = \phi f_t.$$

atau:

$$\hat{f}_{t+1} = \sum_{k=0}^K A_k f_{t-k}.$$

AB.43. Namun ada pendekatan yang lebih konservatif

Untuk short-term trading, kita tidak harus mencoba memprediksi seluruh market.

Kita dapat memisahkan:

$$\hat{\mu}_i = \hat{\mu}_i^{baseline} + \hat{\mu}_i^{factor} + \hat{\mu}_i^{residual}.$$

Ini lebih fleksibel.

AB.44. Baseline component

Misalnya:

$$\hat{\mu}_i^{baseline} = \alpha_i.$$

Tetapi intercept saja biasanya terlalu lemah.

Maka kita dapat memasukkan momentum.

AB.45. Momentum component

$$\hat{\mu}_i^{mom} = \theta_i^{(1)} M_{i,t}^{(1)} + \theta_i^{(6)} M_{i,t}^{(6)} + \theta_i^{(24)} M_{i,t}^{(24)}.$$

AB.46. Factor component

$$\hat{\mu}_i^{factor} = \hat{B}_{i,t} \hat{f}_{t+1}.$$

AB.47. Residual component

Residual return dapat memiliki autocorrelation:

$$\epsilon_{i,t} = \phi_i \epsilon_{i,t-1} + u_{i,t}.$$

Maka:

$$\hat{\epsilon}_{i,t+1} = \hat{\phi}_i \epsilon_{i,t}.$$

AB.48. Gabungan

Kita memperoleh:

$$\hat{\mu}_{i,t} = \alpha_i + \hat{B}_{i,t} \hat{f}_{t+1} + \hat{\phi}_i \epsilon_{i,t} + \hat{\mu}_{i,t}^{mom}.$$

Ini menjadi baseline forecast engine kita.

AB.49. Tapi ada masalah penting

Kalau kita memasukkan terlalu banyak model:

$$\hat{\mu} = \alpha + factor + momentum + residual + interaction + regime + \dots$$

maka kita dapat mengalami:

overfitting.

Karena itu semua coefficient harus dipelajari **hanya dari training window**.

AB.50. Regime conditioning

Kita sebelumnya telah menetapkan 3-state regime.

Misalkan:

$$z_t \in \{1, 2, 3\}.$$

Contoh:

$$1 = \text{Calm}$$

$$2 = \text{Normal}$$

$$3 = \text{Stress}.$$

Maka:

$$\mu_{i,t} = \mu_i(z_t).$$

Dan:

$$\Sigma_t = \Sigma(z_t).$$

AB.51. Mengapa regime mempengaruhi covariance?

Karena:

$$\text{Cov}(r_t \mid z_t = 1) \neq \text{Cov}(r_t \mid z_t = 3).$$

Saat stress:

$$\sigma_i \uparrow$$

dan sering:

$$\rho_{ij} \uparrow .$$

Jadi diversification dapat menjadi lebih lemah saat crash.

Ini sangat penting bagi optimizer.

AB.52. Regime-conditioned factor beta

Kita bahkan dapat mendefinisikan:

$$\beta_{i,k}^{(z)}$$

sehingga:

$$r_{i,t} = \alpha_i^{(z_t)} + B_i^{(z_t)} f_t + \epsilon_{i,t}.$$

Tetapi untuk baseline kita **tidak langsung melakukan ini**, karena parameter akan terlalu banyak.

Kita mulai dengan:

$$B_t$$

rolling dan:

$$z_t$$

sebagai feature.

AB.53. Feature vector final

Untuk asset i , baseline feature vector:

$$\mathbf{x}_{i,t} = \begin{bmatrix} M_i^{(1)} \\ M_i^{(6)} \\ M_i^{(24)} \\ M_i^{(168)} \\ Z_i^{(1)} \\ \sigma_i \\ V Z_i \\ Range_i \\ RM_i^{(24)} \\ \beta_{i,BTC} \\ \beta_{i,ETH} \\ \beta_{i,DXY} \\ \beta_{i,Gold} \\ \beta_{i,SPX} \\ \beta_{i,VIX} \\ \epsilon_{i,t} \\ Z_t \end{bmatrix}.$$

Ini sudah cukup kaya.

AB.54. Tetapi optimizer tidak menerima feature vector

Ini perbedaan penting.

Feature vector:

$$\mathbf{x}_{i,t}$$

masuk ke:

$$Forecast\ Model.$$

Outputnya:

$$\hat{\mu}_{i,t}.$$

Sementara covariance engine menghasilkan:

$$\hat{\Sigma}_t.$$

Barulah:

$$(\hat{\mu}_t, \hat{\Sigma}_t)$$

dikirim ke optimizer.

AB.55. Pipeline matematis lengkap

Sekarang:

$$P, V, OB, F$$

menjadi:

↓

$$r, \sigma, M, VZ, OBI$$

menjadi:

↓

$$B_t, \epsilon_t, \Sigma_F, \Sigma_\epsilon$$

menjadi:

↓

$$\hat{\mu}_t, \hat{\Sigma}_t$$

menjadi:

↓

$$QUBO_t$$

menjadi:

↓

$$x_t^*$$

AB.56. Dari (μ, Σ) ke QUBO

Sekarang kita hubungkan langsung dengan penelitian quantum kita.

Misalkan binary:

$$x_i \in \{0, 1\}.$$

Objective:

$$\min_x [-\hat{\mu}_t^\top x + \lambda x^\top \hat{\Sigma}_t x + C(x)].$$

Jika:

$$C(x)$$

berisi constraint/penalty.

AB.57. Ekspansi quadratic

Karena:

$$x^\top \Sigma x = \sum_i \Sigma_{ii} x_i + 2 \sum_{i < j} \Sigma_{ij} x_i x_j,$$

maka:

$$H(x) = \sum_i Q_{ii} x_i + \sum_{i < j} Q_{ij} x_i x_j + C(x).$$

Dengan koefisien berasal dari:

$$\hat{\mu}_t \quad \text{dan} \quad \hat{\Sigma}_t.$$

Jadi feature engine secara langsung menentukan Hamiltonian.

AB.58. Konsekuensi yang sangat penting

Artinya quantum optimizer **tidak perlu mengetahui harga**.

VQE/QAOA hanya menerima:

$$H_C.$$

Semua financial intelligence terjadi sebelumnya:

$$\boxed{Market \rightarrow Statistics \rightarrow Forecast \rightarrow Risk \rightarrow QUBO.}$$

Kemudian quantum algorithm melakukan:

$$\boxed{QUBO \rightarrow Optimal Configuration.}$$

Ini adalah pemisahan arsitektur yang sangat bersih.

AB.59. Ini juga membuat perbandingan quantum menjadi fair

Exact solver:

$$H_C \rightarrow x^*.$$

Classical heuristic:

$$H_C \rightarrow x^*.$$

VQE:

$$H_C \rightarrow x^*.$$

QAOA:

$$H_C \rightarrow x^*.$$

Semuanya menerima:

$$\boxed{\text{exactly the same } (\mu_t, \hat{\Sigma}_t).}$$

Jadi kalau performanya berbeda, kita dapat mengatribusikan perbedaan kepada **optimizer**, bukan data pipeline.

AB.60. Sekarang kita dapat memperkenalkan "alpha"

Kita tidak boleh menganggap:

$$\hat{\mu}_i$$

sebagai return mentah.

Lebih baik:

$$\alpha_{i,t} = \hat{\mu}_{i,t} - \hat{c}_{i,t}$$

dengan:

$$\hat{c}_{i,t} = \text{fee} + \text{spread} + \text{slippage} + \text{funding}$$

untuk crypto/perpetual bila relevan.

Sehingga optimizer bekerja pada:

$$\text{expected net return.}$$

AB.61. Risk-adjusted alpha

Kita dapat menambahkan:

$$A_{i,t} = \frac{\hat{\mu}_{i,t}}{\hat{\sigma}_{i,t} + \epsilon}$$

Tetapi saya tidak menyarankan mengganti μ dengan A secara langsung.

Lebih baik optimizer tetap menggunakan:

$$\hat{\mu}, \hat{\Sigma}$$

karena covariance sudah menangani risk secara eksplisit.

AB.62. Signal confidence

Kita juga dapat mengukur confidence:

$$C_{i,t} = \frac{|\hat{\mu}_{i,t}|}{SE(\hat{\mu}_{i,t}) + \epsilon}.$$

Ini dapat digunakan sebagai filter:

$$C_{i,t} < C_{min} \Rightarrow x_i = 0.$$

Namun ini sebaiknya menjadi eksperimen terpisah.

AB.63. Prediction uncertainty

Lebih formal:

$$\hat{\mu}_i \pm z_{\alpha/2} SE(\hat{\mu}_i).$$

Jika interval:

$$CI(\mu_i)$$

mencakup nol, kita dapat menganggap signal lemah.

Ini akan sangat berguna untuk **trade selection**.

AB.64. Jangan membuang signal negatif secara otomatis

Ini penting.

Misalkan:

$$\hat{\mu}_i = -0.5\%.$$

Dalam long-only portfolio, asset tersebut mungkin tidak dipilih.

Tetapi dalam sistem long-short:

$$x_i$$

dapat berarti:

$$x_i = 1$$

untuk posisi short.

Jadi architecture kita sebaiknya dari awal tidak terlalu mengunci:

long – only.

AB.65. Binary encoding untuk long-short

Kita dapat menggunakan dua binary variable:

$$x_i^+$$

dan:

$$x_i^-.$$

Dengan constraint:

$$x_i^+ + x_i^- \leq 1.$$

Exposure:

$$q_i = x_i^+ - x_i^-.$$

Sehingga:

$$q_i \in \{-1, 0, +1\}.$$

Ini jauh lebih cocok untuk trading.

AB.66. Ini akan menjadi penting pada tahap QUBO berikutnya

Karena:

$$q_i = x_i^+ - x_i^-,$$

maka portfolio objective:

$$-\mu^\top q + \lambda q^\top \Sigma q.$$

Setelah substitusi:

$$q = x^+ - x^-,$$

kita memperoleh QUBO binary.

Ini akan membuat sistem kita mampu memilih:

Long

atau:

Short

atau:

Flat.

AB.67. Feature engine untuk saham

Untuk saham internasional, kita tinggal memperluas factor vector:

$$\mathbf{f}_t = \begin{bmatrix} SPX \\ NDX \\ DXY \\ Gold \\ VIX \\ US10Y \end{bmatrix}.$$

Kemudian:

$$r_{i,t} = \alpha_i + B_i \mathbf{f}_t + \epsilon_{i,t}.$$

Dengan tambahan sector factor jika diperlukan.

AB.68. Mengapa Gold dan DXY sangat menarik?

Karena kita tidak ingin hanya melihat:

$$SPX.$$

Kita ingin melihat kondisi cross-market.

Misalnya:

$$DXY \uparrow$$

dapat merepresentasikan kondisi USD yang menguat.

Sementara:

$$Gold \uparrow$$

dapat membawa informasi mengenai demand terhadap safe-haven/real-rate/inflation-related dynamics.

Tetapi kita **tidak akan hard-code** interpretasi seperti:

$$DXY \uparrow \Rightarrow Stock \downarrow .$$

Model harus belajar:

$$\beta_{i,DXY,t}.$$

AB.69. Factor exposure sebagai feature dinamis

Maka untuk setiap saham:

$$\beta_{i,t} = [\beta_{i,SPX,t}, \beta_{i,NDX,t}, \beta_{i,DXY,t}, \beta_{i,Gold,t}, \beta_{i,VIX,t}, \beta_{i,US10Y,t}].$$

Ini sangat menarik karena optimizer nantinya dapat memilih asset berdasarkan:

expected return + risk + factor exposure.

AB.70. Portfolio-level factor risk

Setelah optimizer menghasilkan:

$$w,$$

factor exposure portfolio:

$$\beta_p = w^\top B.$$

Misalnya kita ingin membatasi:

$$|\beta_{p,DXY}| \leq B_{max}.$$

Maka constraint dapat dimasukkan ke QUBO.

Ini berarti optimizer bukan hanya memilih:

"asset mana yang profit-nya paling besar?"

tetapi:

"kombinasi asset mana yang menghasilkan expected return tinggi dengan exposure faktor yang masih dapat diterima?"

AB.71. Ini mulai mendekati problem institutional portfolio construction

Karena kita memiliki:

$$\max \quad Expected \text{ Return}$$

dengan:

$$Risk$$

dan:

$$Factor \text{ Exposure}$$

dan:

Transaction Cost

dan:

Liquidity

dan:

Position Constraints.

Kemudian seluruhnya dipetakan menjadi:

$QUBO \rightarrow Ising \rightarrow VQE/QAOA.$

AB.72. Namun jangan memasukkan semuanya sekaligus

Kita perlu menjaga eksperimen bertingkat.

Saya ingin baseline AB menjadi:

Price + Momentum + Volatility + Volume + Cross-market Factor

Kemudian:

AB-1

Price only.

AB-2

Price + momentum.

AB-3

Price + momentum + volatility.

AB-4

- BTC/ETH.

AB-5

- DXY/Gold/SPX/VIX.

AB-6

- residual momentum.

AB-7

- order flow.

Dengan demikian kita bisa mengukur:

$$\Delta Performance$$

dari setiap kelompok feature.

AB.73. Feature leakage test

Setiap feature harus memenuhi:

$$x_{i,t} = f(D_{\leq t}).$$

Contoh yang benar:

$$M_{i,t}^{24} = \ln \frac{P_{i,t}}{P_{i,t-24}}.$$

Contoh yang salah:

$$M_{i,t}^{24} = \ln \frac{P_{i,t+1}}{P_{i,t-23}}.$$

Yang kedua sudah melihat masa depan.

AB.74. Feature normalization

Jika model machine learning digunakan, normalisasi juga harus rolling/training-only.

Misalnya:

$$z_{i,t} = \frac{x_{i,t} - \mu_x}{\sigma_x}.$$

Tetapi:

$$\mu_x, \sigma_x$$

harus dihitung hanya dari training data.

Bukan:

2021 – 2026

secara keseluruhan.

AB.75. Feature stationarity

Kita harus membedakan:

Price

dengan:

Return.

Harga biasanya non-stationary.

Return lebih dekat ke stationary process.

Karena itu model utama sebaiknya bekerja dengan:

returns, ratios, z-scores, factor exposures

daripada harga mentah.

AB.76. Feature covariance

Feature sendiri juga dapat berkorelasi.

Misalnya:

BTC momentum



dan:

ETH momentum

sangat correlated.

Jika terlalu banyak feature serupa, model dapat menjadi unstable.

Ridge regularization akan membantu.

AB.77. Feature selection

Kita dapat memilih feature berdasarkan:

$$IC = \text{Corr}(x_{i,t}, r_{i,t+1}).$$

Ini disebut Information Coefficient.

Namun kita harus menghitungnya **out-of-sample** atau dalam training window.

Jangan memilih feature berdasarkan seluruh history.

AB.78. Information coefficient

Untuk feature x :

$$IC_t = \text{Corr}_i(x_{i,t}, r_{i,t+1}).$$

Jika:

$$IC > 0,$$

feature cenderung memiliki hubungan positif dengan future cross-sectional return.

Tetapi satu IC tidak cukup.

Kita ingin:

$$IC_t$$

stabil sepanjang waktu.

AB.79. IC stability

Kita dapat mengukur:

$$\overline{IC}$$

dan:

$$\sigma_{IC}.$$

Kemudian:

$$ICIR = \frac{\overline{IC}}{\sigma_{IC}}.$$

Feature dengan:

$$ICIR$$

lebih tinggi cenderung lebih konsisten.

Tetapi tetap harus diuji out-of-sample.

AB.80. Sekarang hubungan dengan \$1 risk

Semua estimasi:

$$\hat{\mu}_i, \hat{\sigma}_i$$

akan masuk ke position sizing.

Jika stop distance:

$$d_i = |P_{entry,i} - P_{SL,i}|,$$

maka quantity:

$$q_i = \frac{1}{d_i + \text{cost adjustment}}$$

untuk target risk:

$$R = \$1.$$

Namun quantity ini **belum final**, karena nanti kita juga harus mempertimbangkan:

portfolio risk.

AB.81. Individual risk vs portfolio risk

Ini sangat penting.

Dua posisi:

SOL

dan:

AVAX

masing-masing mempunyai:

\$1

stop risk.

Bukan berarti portfolio risk:

\$2

secara efektif, karena mereka dapat sangat correlated.

Jika:

$$\rho_{SOL,AVAX} \approx 1,$$

maka keduanya sebenarnya satu common risk cluster.

Karena itu covariance matrix:

$$\Sigma_t$$

menjadi sangat penting.

AB.82. Portfolio variance

Jika:

$$w$$

adalah position vector:

$$\sigma_p^2 = w^\top \Sigma_t w.$$

Ini akan menjadi bagian utama objective QUBO.

AB.83. Jadi seluruh AB dapat diringkas menjadi satu persamaan

Saya ingin kita menyimpan persamaan ini sebagai **persamaan inti Stage AB**:

$$\mathbf{r}_{t+1} = \boldsymbol{\alpha}_t + B_t \mathbf{f}_{t+1} + \boldsymbol{\epsilon}_{t+1}$$

dengan:

$$\boldsymbol{\mu}_t = \boldsymbol{\alpha}_t + \hat{B}_t \hat{\mathbf{f}}_{t+1} + \boldsymbol{\mu}_t^{mom} + \boldsymbol{\mu}_t^{res}$$

dan:


$$\hat{\Sigma}_t = \hat{B}_t \hat{\Sigma}_{F,t} \hat{B}_t^\top + \hat{D}_{\epsilon,t}.$$

Kemudian:

$$(\boldsymbol{\mu}_t, \hat{\Sigma}_t) \rightarrow QUBO_t.$$

AB.84. Arsitektur final setelah Tahap AB

Sekarang sistem kita memiliki struktur:



AB.85. Hal yang sekarang sudah kita miliki

Setelah Tahap AB, kita tidak lagi mempunyai sekadar:

"model melihat harga BTC, ETH, Gold, dan DXY."

Kita mempunyai konstruksi matematis:

Price → Return → Feature → Factor Exposure → Expected Return + Covariance → QUBO.

Dan yang paling penting:

Quantum computing berada di ujung pipeline, bukan dipaksakan menjadi model prediksi harga.

Ini menurutku adalah posisi yang jauh lebih kuat secara metodologis.

AB.86. Apa yang belum kita selesaikan?

Ada satu bagian besar yang sengaja **belum** kita masukkan secara penuh:

Order Flow / Market Microstructure.

Kita baru memiliki:

OHLCV + Cross-Asset + Factor Model.

Tahap berikutnya akan membawa:

Bid/Ask + Spread + Depth + Order Book Imbalance + Trade Flow + Liquidity + Slippage

ke dalam sistem.

Dan ini akan sangat penting karena tujuan akhir kita bukan sekadar:

prediksi return,

tetapi:

menentukan apakah sebuah order limit benar-benar layak diletakkan pada harga tertentu.

Dengan kata lain, **Tahap AC seharusnya menjadi Market Microstructure & Order-Flow Engine**. Di sana kita bisa mulai menurunkan secara matematis bagaimana:

Order Book → Fill Probability → Expected Execution Price → Slippage → Net Alpha,

yang kemudian akan mengubah μ_t dari **expected market return** menjadi **expected executable return**. Itu merupakan jembatan penting sebelum kita benar-benar memasukkan order ke sistem QUBO.