

Prompt:

8/17/2026, 10:21:13 PM

lanjut Tahap AF

Response:

8/17/2026, 10:21:14 PM

Remembering

Continued quantitative trading workflow with Stage AF objectives and risk constraints

Worked for 4s

Tahap AF - Portfolio-Level Trade Selection & Cross-Asset Risk Optimization

Kita sekarang masuk ke salah satu bagian **paling penting** dari arsitektur yang kita bangun.

Sampai Tahap AE, kita sudah dapat mengatakan apakah **satu trade secara individual** mempunyai edge yang layak:

$$EV_i > 0.$$

Tetapi dalam trading nyata, masalahnya bukan memilih satu trade.

Misalkan pada satu waktu sistem menemukan:

- 15 peluang crypto,
- 80 saham AS,
- 20 ETF,
- beberapa aset Eropa/Asia,
- gold,
- USD-related instruments,

dan 40 di antaranya memiliki:

$$EV_i > 0.$$

Kita **tidak otomatis mengambil 40 trade tersebut**.

Karena bisa saja 20 trade sebenarnya merupakan taruhan yang hampir sama:

$BTC, ETH, SOL, altcoin_1, altcoin_2, \dots$

semuanya akan jatuh ketika satu faktor market mengalami shock.

Maka pertanyaan Tahap AF adalah:

Bagaimana memilih kombinasi trade terbaik secara simultan dengan mempertimbangkan risiko seluruh portfolio?

Dan di sinilah **portfolio optimization, QUBO, Ising, Max-Cut, dan QAOA** mulai mempunyai fungsi yang sangat natural dalam sistem kita.

AF.1. Perubahan paradigma

Sebelumnya:

Trade Selection

sekarang:

Portfolio Construction

Misalkan terdapat N opportunity:

$$T = \{T_1, T_2, \dots, T_N\}.$$

Untuk setiap trade i , kita mempunyai:

$$EV_i,$$

risk:

$$\sigma_i,$$

dan exposure terhadap trade lain:

$$\rho_{ij}.$$

Maka kita mencari:

$$\mathbf{x}^*$$

dengan:

$$x_i = \begin{cases} 1, & \text{trade } i \text{ dipilih} \\ 0, & \text{trade } i \text{ tidak dipilih.} \end{cases}$$

Jadi secara langsung kita telah mendapatkan **binary optimization problem**.

AF.2. Mengapa binary variable?

Karena pada tahap awal kita tidak perlu menentukan berapa besar posisi.

Kita terlebih dahulu menjawab:

Apakah trade ini diambil atau tidak?

Dengan:

$$x_i \in \{0, 1\}.$$

Kemudian tahap berikutnya menentukan:

$$w_i$$

atau position size.

Jadi kita memisahkan:

Trade Selection

dari:

Position Sizing.

Ini akan sangat membantu ketika kita ingin mengubah masalah menjadi QUBO.

AF.3. Expected return portfolio

Jika trade i mempunyai expected return:

$$\mu_i,$$



maka expected portfolio return:

$$E[R_p] = \sum_{i=1}^N x_i \mu_i.$$

Dalam bentuk vektor:

$$E[R_p] = \mathbf{x}^\top \boldsymbol{\mu}.$$

AF.4. Portfolio variance

Sekarang masalah menjadi lebih menarik.

Jika:

$$\Sigma_{ij} = \text{Cov}(R_i, R_j),$$

maka:

$$\text{Var}(R_p) = \mathbf{x}^\top \Sigma \mathbf{x}.$$

Ekspansinya:

$$\text{Var}(R_p) = \sum_i x_i^2 \sigma_i^2 + 2 \sum_{i < j} x_i x_j \Sigma_{ij}.$$

Karena:

$$x_i^2 = x_i$$

untuk binary variable, maka:

$$\text{Var}(R_p) = \sum_i x_i \sigma_i^2 + 2 \sum_{i < j} x_i x_j \Sigma_{ij}.$$

Dan di sinilah coupling antar-trade muncul.

AF.5. Interpretasi fisiknya

Perhatikan:

$$x_i x_j \Sigma_{ij}.$$

Jika:

$$\Sigma_{ij} > 0,$$

maka mengambil i dan j sekaligus meningkatkan variance.

Jika:

$$\Sigma_{ij} < 0,$$

maka mengambil keduanya dapat memberikan diversification benefit.

Jadi:

$$\boxed{\Sigma_{ij}}$$

secara matematis berperan sebagai **interaction energy** antar opportunity.

Ini akan sangat berguna untuk pemetaan ke Ising.

AF.6. Tetapi covariance saja belum cukup

Untuk sistem kita, covariance antar aset bukan satu-satunya sumber risiko.

Misalkan:

$$R_i = \alpha_i + \boldsymbol{\beta}_i^\top \mathbf{F} + \epsilon_i.$$

Dengan:

$$\mathbf{F} = \begin{bmatrix} F_{BTC} \\ F_{ETH} \\ F_{Gold} \\ F_{USD} \\ F_{Market} \\ \vdots \end{bmatrix}.$$

Maka:

$$R_i = \alpha_i + \boldsymbol{\beta}_i^\top \mathbf{F} + \epsilon_i.$$

Ini adalah **factor model**.

AF.7. Mengapa factor model penting?

Misalkan:

$$\text{Corr}(BTC, SOL) = 0.85.$$

Itu sudah menunjukkan korelasi.

Tetapi kita ingin mengetahui **mengapa**.

Mungkin keduanya mempunyai exposure besar terhadap:

$$F_{\text{Crypto}}.$$

Demikian pula:

$$AAPL, MSFT, NVDA$$

mungkin semuanya memiliki exposure terhadap:

$$F_{\text{Tech}}.$$

Sementara:

$$Gold$$

dan:

$$USD$$

mempunyai exposure terhadap faktor makro yang berbeda.

AF.8. Factor exposure portfolio

Jika trade i memiliki:

$$\beta_i,$$

maka exposure portfolio terhadap factor k :

$$B_k = \sum_i x_i \beta_{ik}.$$

Dalam bentuk matriks:

$$\mathbf{B} = \mathbf{B}^\top \mathbf{x}.$$

Kita kemudian dapat memberikan constraint:

$$|B_k| \leq B_k^{\max}.$$

AF.9. Contoh

Misalkan:

$$\beta_{BTC} = 1.2$$

terhadap crypto factor.

Dan:

$$\beta_{SOL} = 1.5.$$

Jika:

$$x_{BTC} = x_{SOL} = 1,$$

maka:

$$B_{crypto} = 2.7.$$

Kalau batas kita:

$$B_{crypto}^{max} = 2,$$

maka kombinasi tersebut tidak diperbolehkan.

AF.10. Ini jauh lebih baik daripada sekadar membatasi jumlah trade

Misalnya kita menetapkan:

$$\sum_i x_i \leq 10.$$

Ini tidak menjamin diversification.

Sepuluh trade bisa saja:

$$BTC, ETH, SOL, AVAX, DOGE, \dots$$

yang semuanya sangat terpapar faktor crypto yang sama.

Sebaliknya:

$$5 \text{ crypto} + 3 \text{ equity} + 1 \text{ gold} + 1 \text{ FX}$$

mungkin mempunyai diversification jauh lebih baik.

AF.11. Objective dasar

Kita dapat menggunakan objective:

$$\max_{\mathbf{x}} [\mathbf{x}^T \boldsymbol{\mu} - \lambda \mathbf{x}^T \Sigma \mathbf{x}].$$

Dengan:

$$\lambda > 0$$

sebagai risk-aversion parameter.

Ini merupakan bentuk discrete Markowitz optimization.

AF.12. Hubungan dengan Markowitz

Markowitz klasik:

$$\max_{\mathbf{w}} [\mathbf{w}^T \boldsymbol{\mu} - \lambda \mathbf{w}^T \Sigma \mathbf{w}].$$

Tetapi sekarang:

$$w_i \rightarrow x_i \in \{0, 1\}.$$

Maka:

$$\boxed{\text{Continuous Markowitz} \rightarrow \text{Binary Portfolio Optimization.}}$$

Dan masalah ini dapat menjadi combinatorial optimization.

AF.13. Mengapa ini menarik untuk QUBO?

Objective:

$$\mathbf{x}^T \boldsymbol{\mu} - \lambda \mathbf{x}^T \Sigma \mathbf{x}$$

sudah merupakan quadratic function terhadap binary variables.

QUBO didefinisikan sebagai:

$$\boxed{\min_{\mathbf{x} \in \{0,1\}^N} \mathbf{x}^T Q \mathbf{x}.$$

Jadi secara struktural:

$$\boxed{\text{Portfolio Selection} \approx \text{QUBO.}}$$

AF.14. Sign convention

Karena kita ingin memaksimalkan:

$$\boldsymbol{\mu}^T \mathbf{x} - \lambda \mathbf{x}^T \Sigma \mathbf{x},$$

kita dapat mengubahnya menjadi minimisasi:

$$\min_x [-\mu^T x + \lambda x^T \Sigma x].$$

Maka:

$$Q$$

dibangun dari:

$$-\mu + \lambda \Sigma.$$

Dengan perhatian khusus terhadap konvensi diagonal/off-diagonal QUBO yang digunakan implementasi kita.

AF.15. Constraint jumlah trade

Katakanlah maksimal:

$$K$$

trade boleh dibuka.

Constraint:

$$\sum_i x_i = K.$$

Untuk mengubahnya menjadi unconstrained QUBO, kita tambahkan penalty:

$$P \left(\sum_i x_i - K \right)^2.$$

Sehingga:

$$C(x) = -\mu^T x + \lambda x^T \Sigma x + P \left(\sum_i x_i - K \right)^2.$$

AF.16. Ekspansi penalty

Perhatikan:

$$\frac{1}{2} (\sum_i x_i - K)^2.$$

Kita punya:

$$= \sum_i x_i^2 + 2 \sum_{i < j} x_i x_j - 2K \sum_i x_i + K^2.$$

Karena:

$$x_i^2 = x_i,$$

maka:

$$= \sum_i x_i + 2 \sum_{i < j} x_i x_j - 2K \sum_i x_i + K^2.$$

Jadi penalty tetap quadratic.

AF.17. Constraint factor exposure

Misalkan:

$$B^T x \leq B_{max}.$$

Kita dapat menggunakan slack variables atau penalty.

Untuk constraint equality sederhana:

$$B^T x = B_0,$$

gunakan:

$$P_B (B^T x - B_0)^2.$$

Untuk inequality:

$$B^T x \leq B_{max},$$

kita dapat memperkenalkan slack:

$$B^T x + s = B_{max}.$$

AF.18. Risk budget

Kita dapat membatasi:

$$x^T \Sigma x \leq \sigma_{max}^2.$$

Secara langsung ini merupakan quadratic constraint.

Dengan penalty:

$$P_{\sigma} (x^T \Sigma x - \sigma_{max}^2)^2.$$

Namun ini menghasilkan polynomial degree 4 jika diekspansi.

Jadi untuk QUBO murni kita harus berhati-hati.

AF.19. Solusi yang lebih baik

Kita tidak harus memaksakan semua constraint menjadi QUBO sekaligus.

Kita dapat menggunakan:

$$\textit{Hierarchical Optimization.}$$

Contohnya:

Layer 1

Filter opportunity:

$$EV_i > EV_{min}.$$

Layer 2

Risk screening:

$$\sigma_i < \sigma_{max}.$$

Layer 3

Factor exposure screening.

Layer 4

QUBO:

$$\max [EV - \lambda Risk].$$

Ini membuat problem jauh lebih tractable.

AF.20. Hard constraint versus soft constraint

Kita harus membedakan:

Hard constraint

Tidak boleh dilanggar.

Contoh:

$$\sum_i x_i \leq K.$$

Soft constraint

Boleh dilanggar dengan penalty.

Contoh:

factor exposure.

Maka objective:

$$J = \text{Reward} - \text{Risk} - \text{Penalty}.$$

AF.21. Cross-asset factor matrix

Sekarang kita mulai membangun struktur yang lebih besar.

Misalkan terdapat:

$$N = 100$$

trade opportunities.

Dan:

$$K = 8$$

factor.

Kita memiliki:

$$B \in \mathbb{R}^{100 \times 8}.$$

Baris:

$$\beta_i$$

adalah exposure trade i .

Kolom:

$$k$$

adalah factor.

AF.22. Faktor yang kita inginkan

Untuk desain awal sistem universal, saya akan menggunakan kelompok faktor:

$\{Market, Sector, Crypto, USD, Gold, Rates, Volatility, Liquidity\}.$

Kemudian universe tertentu dapat menambahkan faktor spesifik.

AF.23. Contoh

Untuk BTC:

$$\beta_{BTC} = \begin{bmatrix} 1.1 \\ 0 \\ 1.4 \\ -0.2 \\ 0.1 \\ 0 \\ 1.5 \\ 1.8 \end{bmatrix}.$$

Untuk gold:

$$\beta_{Gold} = \begin{bmatrix} 0.1 \\ 0 \\ 0 \\ -0.5 \\ 1.2 \\ -0.3 \\ 0.4 \\ 0.5 \end{bmatrix}.$$

Angka ini hanya ilustrasi; dalam sistem nyata semuanya harus diestimasi secara point-in-time.

AF.24. Faktor USD

Ini sangat relevan dengan tujuanmu.

Misalkan:

$$F_{USD}$$

merepresentasikan kekuatan USD.

Kita dapat memasukkan:

$$\beta_{i,USD}.$$

Jika portfolio terlalu long terhadap aset yang sensitif terhadap pelemahan USD, maka kita dapat membatasi:

$$\boxed{|B_{USD}| \leq B_{USD}^{max}}.$$

AF.25. Gold sebagai macro hedge

Demikian pula:

$$F_{Gold}.$$

Gold bukan hanya sebuah aset untuk ditrade.

Ia juga dapat berfungsi sebagai:

risk factor

atau:

hedging instrument.

Ini merupakan perbedaan penting antara:

trading gold

dan:

menggunakan gold sebagai komponen risk model.

AF.26. Covariance decomposition

Factor model memberi:

$$R = BF + \epsilon.$$

Jika:

$$\text{Cov}(F) = \Sigma_F$$

dan:

$$\text{Cov}(\epsilon) = D,$$

maka:

$$\Sigma = B\Sigma_F B^\top + D.$$

Ini sangat penting.

Kita tidak harus mengestimasi covariance antar 500 aset secara langsung.

Kita dapat memecahnya menjadi:

$$\text{Systematic Risk} + \text{Idiosyncratic Risk}.$$

AF.27. Mengapa ini sangat cocok untuk pasar besar?

Misalkan:

$$N = 1000.$$

Covariance matrix:

$$1000 \times 1000.$$

Jumlah elemen:

$$10^6.$$

Estimasi langsung dapat menjadi noisy.

Tetapi jika:

$$K = 20$$

factor, kita dapat menggunakan:

$$B_{1000 \times 20}.$$

Jauh lebih manageable.

AF.28. Risk portfolio factor

Variance:

$$\text{Var}(R_p) = x^\top (B \Sigma_F B^\top + D) x.$$

Pisahkan:

$$= x^\top B \Sigma_F B^\top x + x^\top D x.$$

Karena:

$$B^\top x$$

adalah portfolio factor exposure, maka:

$$\boxed{\text{Var}(R_p) = (B^\top x)^\top \Sigma_F (B^\top x) + x^\top D x.}$$

Ini memberikan interpretasi yang sangat bagus:

$$\boxed{\text{Portfolio Risk} = \text{Factor Risk} + \text{Idiosyncratic Risk}.}$$

AF.29. Trade clustering

Kita dapat mendefinisikan similarity:

$$S_{ij} = \beta_i^\top W \beta_j.$$

Jika:

$$S_{ij} \gg 0,$$

maka trade i, j memiliki exposure serupa.

Kita dapat memberikan penalty:

$$\boxed{\lambda_S \sum_{i < j} S_{ij} x_i x_j.}$$

Ini akan mendorong diversification.

AF.30. Hubungan dengan Max-Cut

Menariknya, jika kita memiliki graph:

$$G = (V, E),$$

dengan:

$$w_{ij}$$

sebagai similarity/exposure, kita dapat menginginkan agar node-node yang sangat berkorelasi tidak dipilih bersama.

Ini dapat diformulasikan sebagai graph optimization.

Max-Cut klasik:

$$\max \sum_{i < j} w_{ij} x_i (1 - x_j)$$

atau equivalent formulations.

Jadi:

$$\text{Correlation management} \rightarrow \text{Graph problem.}$$

AF.31. Mengapa kita tidak langsung menggunakan Max-Cut?

Karena tujuan utama kita bukan:

memotong graph.

Tujuan kita:

$$\text{maximize expected utility while controlling risk.}$$

Max-Cut hanya menjadi salah satu substructure yang dapat muncul.

AF.32. QUBO general form

Kita dapat menulis:

$$H(x) = - \sum_i a_i x_i + \sum_{i < j} J_{ij} x_i x_j + P(x).$$

Interpretasinya:

$$a_i$$

adalah individual attractiveness.

Sedangkan:

$$J_{ij}$$

adalah interaction.

AF.33. Dalam sistem kita

Kita dapat membuat:

$$a_i = EV_i - \lambda \sigma_i^2$$

dan:

$$J_{ij} = 2\lambda \Sigma_{ij} + \lambda_F S_{ij}.$$

Sehingga:

$$H(x) = - \sum_i (EV_i - \lambda \sigma_i^2) x_i + \sum_{i < j} J_{ij} x_i x_j + P \text{ enalties}.$$

AF.34. Ini adalah titik penting

Perhatikan struktur:

$$EV_i$$



berasal dari:

probabilistic trading model.

Sedangkan:

$$J_{ij}$$

berasal dari:

cross-trade interaction.

Jadi optimizer tidak lagi hanya bertanya:

"Trade mana paling profitable?"

Ia bertanya:

"Trade mana yang paling menguntungkan setelah memperhitungkan apa yang sudah kita pilih?"

Itulah perbedaan fundamental antara:

Single Trade Optimization

dan:

Portfolio Optimization.

AF.35. Position sizing setelah selection

Setelah QUBO memilih:

$$x^*,$$

kita belum selesai.

Kita kemudian menyelesaikan continuous optimization:

$$\max_{\mathbf{w}} \quad \mathbf{w}^\top \boldsymbol{\mu} - \lambda \mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w}$$

subject to:

$$w_i = 0 \quad \text{jika } x_i^* = 0.$$

Dengan:

$$w_i \geq 0$$

untuk long-only.

Atau:

$$w_i \in \mathbb{R}$$

untuk long-short.

AF.36. Ini menghasilkan hybrid architecture

Dan ini menurut saya jauh lebih baik daripada mencoba memaksa seluruh masalah menjadi QAOA.

Kita gunakan:

Quantum/Classical Discrete Optimization

untuk:

Which trades?

dan:

Classical Continuous Optimization

untuk:

How much of each?

AF.37. Secara keseluruhan

Data → Prediction → Calibration → Opportunity → QUBO → Selection → Continuous Sizing → Execution.



AF.38. Constraint risk \$1

Sekarang kita hubungkan dengan desain awal kita.

Jika setiap trade harus memiliki maximum loss:

$$R_i = \$1,$$

maka stop-loss distance:

$$d_i = |P_i^{entry} - P_i^{SL}|.$$

Position size:

$$Q_i = \frac{1}{d_i \cdot V_i}$$

dengan V_i conversion factor sesuai instrument.

Dengan demikian:

$$MaxLoss_i \approx \$1.$$

AF.39. Tetapi portfolio risk tidak otomatis \$1

Misalnya kita mengambil 10 trade:

$$R_i = \$1.$$

Worst-case nominal loss:

$$10\$.$$

Tetapi jika semuanya sangat correlated, probabilitas mengalami 10 loss sekaligus bisa jauh lebih besar daripada portfolio yang benar-benar diversified.

Jadi kita membutuhkan:

$$Portfolio Risk$$

di atas:

Trade Risk.

AF.40. Portfolio risk budget

Kita dapat menentukan:

$$R_{\text{portfolio}}^{\max}$$

misalnya dalam unit R .

Kemudian:

$$\text{Risk}(\mathbf{w}) \leq R_{\text{portfolio}}^{\max}.$$

Ini lebih bermakna daripada hanya:

$$\text{Risk}_i = 1R.$$

AF.41. Conditional Value-at-Risk

VaR menjawab:

"Pada confidence level q , berapa threshold loss?"

Misalnya:

$$\text{VaR}_{95\%} = 10R.$$

Tetapi VaR tidak mengatakan seberapa buruk kondisi setelah threshold tersebut dilewati.

CVaR menjawab:

$$\text{CVaR}_q = E[L \mid L \geq \text{VaR}_q].$$

Jadi:

$$\text{CVaR}$$

lebih informatif untuk tail risk.

AF.42. Constraint CVaR

Kita dapat menentukan:

$$CVaR_{95\%} \leq C_{max}.$$

Ini menjadi salah satu constraint portfolio-level.

Untuk implementasi optimization yang lebih kompleks, CVaR dapat diformulasikan menggunakan auxiliary variable.

AF.43. Scenario-based risk

Daripada hanya menggunakan covariance matrix, kita dapat menghasilkan:

$$S$$

scenario.

Misalnya:

$$s = 1, \dots, S.$$

Untuk setiap scenario:

$$R_i^{(s)}.$$

Portfolio loss:

$$L^{(s)} = - \sum_i x_i w_i R_i^{(s)}.$$

Kemudian:

$$VaR, CVaR$$

dihitung dari distribusi:

$$\{L^{(1)}, \dots, L^{(S)}\}.$$

AF.44. Ini sangat penting untuk market shock

Misalnya scenario:

Scenario A

BTC:

−8%.

Scenario B

USD:

+2%.

Scenario C

Gold:

+4%.

Scenario D

Equity:

−5%.

Kita ingin mengetahui:

$$L_p^{(s)}$$

untuk portfolio yang dipilih.

AF.45. Stress testing

Kita dapat secara eksplisit membuat:

Stress Scenarios

seperti:

$$BTC = -10\%$$

$$SPX = -5\%$$

$$USD = +2\%$$

$$Gold = +3\%$$

dan melihat apakah portfolio masih berada dalam risk budget.

AF.46. Ini menghubungkan sistem kita dengan macro regime

Sebelumnya kita memasukkan:

BTC, ETH, Gold, USD.

Sekarang mereka tidak hanya menjadi feature.

Mereka dapat menjadi:

Portfolio Risk Drivers.

Misalnya:

BTC

mengindikasikan crypto risk appetite.

USD

mengindikasikan dollar liquidity.

Gold

mengindikasikan defensive/macro demand.

Jadi macro factors memengaruhi:

Prediction

dan sekaligus:


Risk.

AF.47. Ini membuat arsitektur dua arah

Bukan:

Market → Prediction → Trade

tetapi:



AF.48. Dynamic portfolio optimization

Masalah ini harus diselesaikan setiap:

t .

Jadi:

$$x_t^* = \arg \min_x H_t(x).$$

Karena:

$$EV_t, \Sigma_t, B_t$$

berubah seiring waktu.

Dengan demikian kita sebenarnya memiliki:

$$\textit{Dynamic QUBO}.$$

AF.49. Warm-start

Ini sangat cocok dengan pengalamanmu pada EPG dan VQE.

Jika pada:

$$t - 1$$

kita mempunyai:

$$x_{t-1}^*,$$

maka pada:

$$t$$

solusi biasanya tidak berubah secara ekstrem.

Kita dapat menggunakan:

$$x_{t-1}^*$$

sebagai warm-start.

AF.50. Ini dapat mengurangi computational burden

Daripada menyelesaikan:

$$QUBO_t$$

dari nol setiap saat, kita memulai dari:

$$x_{t-1}^*$$

Kemudian hanya melakukan adjustment terhadap opportunity yang berubah.

Ini sangat cocok untuk short-term trading.

AF.51. Hysteresis

Ada masalah lain.

Jika optimizer terlalu sensitif:

$$x_t$$

bisa berubah:

$$1010101010 \dots$$

setiap periode.

Ini menghasilkan:

- excessive turnover,
- fee,
- slippage.

Maka kita tambahkan switching penalty:

$$\lambda_{switch} \sum_i |x_{i,t} - x_{i,t-1}|.$$

AF.52. Binary switching penalty

Karena:

$$x_{i,t}, x_{i,t-1} \in \{0, 1\},$$

kita dapat menulis:

$$|x_t - x_{t-1}|$$

sebagai:

$$x_t + x_{t-1} - 2x_t x_{t-1}.$$

Jadi tetap quadratic.

Ini sangat menarik karena:

$$\boxed{\text{Turnover control}}$$

juga dapat masuk ke QUBO.

AF.53. Objective lengkap sementara

Kita sekarang dapat menulis:

$$\begin{aligned} H_t(x) = & - \sum_i EV_{i,t} x_i \\ & + \lambda x^\top \Sigma_t x \\ & + \lambda_F R_F(x) \\ & + \lambda_T T(x, x_{t-1}) \\ & + P_K \left(\sum_i x_i - K \right)^2. \end{aligned}$$

Dengan:

- EV_i : expected edge,
- Σ : covariance,
- R_F : factor-risk penalty,
- T : turnover penalty,

- K : maximum number of positions.

AF.54. Dan sekarang kita benar-benar memiliki QUBO trading

Secara konseptual:

$$QUBO_t = Expected\ Edge + Risk + Factor\ Exposure + Turnover + Constraints.$$

Ini bukan lagi QUBO contoh akademik.

Ia berasal langsung dari:

$$portfolio\ management\ problem.$$

AF.55. Mapping ke Ising

Sekarang gunakan transformasi standar:

$$x_i = \frac{1 + z_i}{2}$$

dengan:

$$z_i \in \{-1, +1\}.$$

Kemudian:

$$x_i x_j = \frac{1 + z_i + z_j + z_i z_j}{4}.$$

Maka:

$$H(x)$$

dapat ditulis:

$$H(z) = C + \sum_i h_i z_i + \sum_{i < j} J_{ij} z_i z_j.$$

AF.56. Hamiltonian kuantum

Ganti:

$$Z_i$$

dengan Pauli Z_i :

$$\hat{H}_C = CI + \sum_i h_i Z_i + \sum_{i < j} J_{ij} Z_i Z_j.$$

Dan ini persis bentuk Ising Hamiltonian yang sebelumnya sudah kita gunakan dalam penelitianmu.

AF.57. Sekarang QAOA memiliki makna trading yang jelas

QAOA menggunakan:

$$U_C(\gamma) = e^{-i\gamma \hat{H}_C}$$

dan:

$$U_M(\beta) = e^{-i\beta \hat{H}_M}.$$

Dengan:

$$\hat{H}_M = \sum_i X_i.$$

State:

$$|\psi(\gamma, \beta)\rangle = U_M(\beta_p) U_C(\gamma_p) \cdots U_M(\beta_1) U_C(\gamma_1) |+\rangle^{\otimes N}.$$

AF.58. Interpretasi state QAOA

State akhir:

$$|\psi\rangle = \sum_x c_x |x\rangle.$$

Probabilitas:

$$P(x) = |c_x|^2.$$

Artinya:

QAOA tidak sekadar menghasilkan satu portfolio; ia menghasilkan distribusi kandidat portfolio.

Ini sangat menarik untuk sistem kita.

AF.59. Candidate portfolio distribution

Misalnya QAOA menghasilkan:

$$P(x_1) = 0.42$$

$$P(x_2) = 0.31$$

$$P(x_3) = 0.11$$

dan seterusnya.

Kita dapat mengambil:

$$x^* = \arg \max_x P(x).$$

Tetapi kita juga dapat mengambil beberapa kandidat:

$$\{x^{(1)}, x^{(2)}, \dots, x^{(K)}\}.$$

AF.60. Ini membuka pendekatan yang lebih menarik

Kita tidak harus berkata:

QAOA menghasilkan portfolio → langsung trading.

Kita dapat:

QAOA → Candidate Portfolios → Classical Risk Filter → Execution.

Jadi quantum optimizer menjadi **candidate generator**.

AF.61. Ini juga menyelesaikan masalah NISQ

Untuk sistem nyata, QAOA tidak harus menghasilkan solusi exact.

Kita cukup mencari:

x

yang:

$H(x)$

cukup rendah.

Kemudian classical validator melakukan:

$RiskCheck(x)$.

Dengan demikian quantum hardware tidak menjadi single point of failure.

AF.62. Objective final yang lebih aman

Saya menyarankan:

Quantum optimizer proposes.

Classical risk engine disposes.

Artinya QAOA boleh mengusulkan portfolio, tetapi risk engine memiliki hak veto.

AF.63. Risk veto

Misalnya QAOA memberikan:

$$x^*.$$

Tetapi:

$$CVaR_{95\%}(x^*) > C_{max}.$$

Maka:

Reject.

Tidak peduli seberapa rendah QUBO energy-nya.

AF.64. Ini sangat penting secara finansial

Kita jangan membuat:

Quantum objective = semua hal.


Karena objective yang salah akan menghasilkan solusi matematis yang benar tetapi keputusan finansial yang buruk.

Maka:

Optimization $\boxtimes$ *Risk Management.*

Risk management tetap menjadi layer independen.

AF.65. Arsitektur AF lengkap



AF.66. Contoh sederhana

Misalkan kita mempunyai lima opportunity:

$A, B, C, D, E.$

Expected edge:

$$\mu = \begin{bmatrix} 0.8 \\ 0.7 \\ 0.6 \\ 0.5 \\ 0.4 \end{bmatrix} R.$$

Secara individual:

$$A > B > C > D > E.$$

Jika kita hanya melihat EV, kita akan memilih:

$$A, B, C.$$

Tetapi ternyata:

$$\text{Corr}(A, B) = 0.95,$$

$$\text{Corr}(A, C) = 0.90.$$

Sedangkan:

$$\text{Corr}(D, A) = 0.1.$$

Maka:

$$A, D, E$$

mungkin lebih optimal daripada:

$$A, B, C.$$

AF.67. Inilah alasan optimizer quadratic diperlukan

Linear selection:

$$\max \sum_i \mu_i x_i$$

tidak dapat melihat:

$$\mu_{ij}.$$

Quadratic objective:

$$\max \left[\sum_i \mu_i x_i - \lambda \sum_{i,j} \Sigma_{ij} x_i x_j \right]$$

dapat melihat interaction.

AF.68. Dan sekarang kita kembali ke tujuan awal kita

Tujuanmu bukan sekadar:

membuat bot crypto.

Kita sedang membangun:

Cross-Asset Quantitative Decision System.

Dengan kemampuan menangani:

Crypto

Equities

ETF

Gold

FX

dan instrumen lain selama data dan execution model tersedia.

AF.69. Struktur universal versus asset-specific

Kita harus menjaga:

Universal

EV

Σ

Factor Exposure

CVaR

Turnover

QUBO

Asset-specific

Microstructure

Fee

Tick Size

Trading Hours

Funding

Shorting Rules

Liquidity.

Dengan demikian arsitektur tetap universal tanpa berpura-pura bahwa crypto dan saham memiliki microstructure identik.

AF.70. Dan sekarang hubungan dengan skripsimu menjadi sangat jelas

Dalam penelitianmu, kita mempunyai:

$$\text{Markowitz} \rightarrow \text{QUBO} \rightarrow \text{Ising} \rightarrow \text{VQE/QAOA}.$$

Pada sistem trading ini kita memperluasnya menjadi:

$$\text{Short-Term Forecast} \rightarrow \text{Expected Trade Return} \rightarrow \text{Cross-Asset Risk} \rightarrow \text{Binary Portfolio} \rightarrow \text{QUBO} \rightarrow \text{Ising} -$$

Jadi quantum optimization bukan tempelan.

Ia muncul **secara alami dari struktur masalah**.

AF.71. Persamaan inti Tahap AF

Kalau seluruh tahap ini harus diringkas menjadi satu persamaan:

$$\begin{aligned} \mathbf{x}_t^* = \arg \min_{\mathbf{x} \in \{0,1\}^N} [& -\mathbf{x}^\top \mathbf{E} \mathbf{V}_t \\ & + \lambda \mathbf{x}^\top \Sigma_t \mathbf{x} \\ & + \lambda_F \|B_t^\top \mathbf{x}\|^2 \\ & + \lambda_T \|\mathbf{x} - \mathbf{x}_{t-1}\|_1 \\ & + P_K (\mathbf{1}^\top \mathbf{x} - K)^2]. \end{aligned}$$

Kemudian:

$$\mathbf{x}_t^* \rightarrow \text{position sizing} \rightarrow \text{execution}.$$

Ini adalah **jantung matematis Tahap AF**.

AF.72. Namun ada satu hal yang sengaja belum kita lakukan

Kita belum memasukkan:

$$w_i$$

secara penuh ke dalam optimizer.

Saat ini:

$$x_i$$

hanya menjawab:

ambil / jangan ambil.

Sedangkan:

$$w_i$$

akan menjawab:

seberapa besar posisi?

Dan ketika kita menggabungkan:

$$x_i$$

dan:

$$w_i,$$

kita mendapatkan problem **mixed discrete-continuous optimization** yang jauh lebih menarik:

$$x_i \in \{0, 1\}, \quad w_i \in \mathbb{R}.$$

Di situlah kita dapat mulai membangun **AF+ / Tahap AG** secara lebih dalam: bagaimana menggabungkan **binary QUBO selection + continuous Markowitz sizing + CVaR + factor neutrality + \$1 stop-loss risk + leverage + liquidity constraints** menjadi satu hierarchical optimizer.

Dan setelah itu, baru kita dapat benar-benar menjawab pertanyaan paling penting dalam sistem kita:

"Dari seluruh peluang yang tersedia sekarang, trade mana yang dipilih, berapa besar posisinya, dan menga



Itulah titik di mana sistem kita mulai berubah dari sekadar **trade signal generator** menjadi **portfolio-level quantitative trading engine**.